ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN 1

TIỀN XỬ LÝ DỮ LIỆU

PHÂN TÍCH THỐNG KÊ – THIẾT KẾ PIPELINE – PHÂN TÍCH & ĐÁNH GIÁ TÁC ĐỘNG

DỮ LIỆU: ẢNH SỐ – DẠNG BẢNG – VĂN BẢN

Môn học:	Khai thác dữ liệu và ứng dụng
Mã học phần:	CSC14004
Học kỳ:	Học kỳ 2 – 2025–2026
Giảng viên hướng dẫn:	Th.S Nguyễn Thị Thu Hằng
	Th.S Nguyễn Ngọc Đức
	Th.S Lê Nhựt Nam

Nhóm sinh viên thực hiện:

Nguyễn Hữu Khánh Hưng	23120271
Phạm Quốc Khánh	23120283
Y Nguyên Mlô	23120299
Vũ Trần Phúc	23120333
Trần Nguyễn Minh Quân	23120342

TP. Hồ Chí Minh, tháng 4 năm 2025

Lời cảm ơn

Nhóm chúng em xin gửi lời cảm ơn chân thành đến đội ngũ giảng viên phụ trách môn *Khai phá dữ liệu* (Data Mining), đặc biệt là thầy Lê Nhựt Nam, đã tận tình hỗ trợ và định hướng trong suốt quá trình thực hiện báo cáo. Những bài giảng, phản hồi chuyên môn và góc nhìn thực tiễn của thầy giúp nhóm hiểu rõ hơn giá trị của từng kỹ thuật tiền xử lý dữ liệu trong bài toán khai thác dữ liệu hiện đại.

Báo cáo này được hoàn thành trên cơ sở nghiên cứu và thực nghiệm với ba loại dữ liệu đặc trưng: dữ liệu ảnh số (Intel Image Classification Dataset), dữ liệu bảng (Amazon Products Sales Dataset) và dữ liệu văn bản (IMDB Movie Reviews Dataset). Nhóm đã nỗ lực đảm bảo tính chính xác, minh bạch trong phân tích và trình bày kết quả một cách có hệ thống, súc tích.

Mặc dù đã dành nhiều tâm huyết và nỗ lực để hoàn thành bản báo cáo một cách chỉn chu nhất, tuy nhiên do kiến thức còn hạn chế, chắc chắn không tránh khỏi những thiếu sót. Nhóm chúng em rất mong nhận được những ý kiến đóng góp và phê duyệt từ các thầy/cô để chúng em có thể hoàn thiện kiến thức của mình hơn trong các chặng đường sắp tới.

TP. Hồ Chí Minh, tháng 4 năm 2025 *Nhóm sinh viên thực hiện*

Contents

Lời cảm ơn **i**

Bảng phân công nhiệm vụ **iv**

Tóm tắt điều hành **v**

1 Giới thiệu **2**

1.1 Mục tiêu và câu hỏi nghiên cứu 2

1.2 Tổng quan tập dữ liệu và cấu trúc báo cáo 2

2 Tiền xử lý và phân tích dữ liệu ảnh số **3**

2.1 Phân tích thống kê tập dữ liệu (EDA) 3

2.1.1 Phân phối pixel và đặc trưng màu sắc 3

2.1.2 Phân tích mất cân bằng lớp 4

2.1.3 Phát hiện ảnh trùng lặp bằng pHash và phân tích độ sáng/tương phản theo lớp 4

2.2 Thay đổi kích thước ảnh – SSIM, PSNR và Ablation Study 5

2.2.1 Mức độ mất mát thông tin (SSIM và PSNR) 5

2.2.2 Ablation Study – Tác động kích thước đến accuracy phân loại . 8

2.3 Chuyển đổi không gian màu 10

2.3.1 Đo lường phương sai giải thích – PCA $k = 50$ 10

2.3.2 Ablation Study – Tác động không gian màu đến accuracy 10

2.4 Chuẩn hóa pixel – Kiểm định KS và Ablation Study 11

2.5 Tăng cường dữ liệu – Data Augmentation 12

2.6 [Nâng cao] Phân tích PCA và t-SNE – Cấu trúc không gian đặc trưng . 15

2.7 [Nâng cao] Phát hiện cạnh – Edge Detection và ANOVA 17

3 Tiền xử lý và phân tích dữ liệu bảng **20**

3.1 Phân tích phân phối – Kiểm định D'Agostino–Pearson 20

3.2 Phân tích tương quan – Pearson vs. Spearman 22
3.3 Phân tích giá trị thiếu – Kiểm định Little's MCAR 23
3.4 So sánh chiến lược điền khuyết – RMSE trên Ground Truth 24
3.5 Phát hiện và xử lý ngoại lai 26
3.6 Chuẩn hóa dữ liệu – Kiểm định Levene 27
3.7 Mã hóa biến phân loại – Phân tích VIF 29
3.8 Lựa chọn đặc trưng và giảm chiều dữ liệu 31
3.9 Phát hiện và xử lý mất cân bằng lớp 32

4 Phân tích và tiền xử lý dữ liệu văn bản 35
4.1 Phân tích phân phối độ dài văn bản 35
4.1.1 Phân phối số từ (Word Count) 36
4.1.2 Phân phối số ký tự (Character Length) 37
4.2 Độ phong phú từ vựng – TTR và Word Cloud 38
4.3 Phân tích định luật Zipf 39
4.4 So sánh kỹ thuật tiền xử lý văn bản 40
4.4.1 Pipeline chuẩn hóa – Tác động định lượng từng bước 40
4.4.2 So sánh chiến lược Tokenization 42
4.4.3 Loại bỏ stop words – Phân tích định lượng MI và Naive Bayes . 43
4.4.4 Stemming và Lemmatization – Collision Rate và 5-fold CV . . . 44
4.5 Vector hóa văn bản – TF-IDF vs. SBERT 45
4.5.1 So sánh tổng quan các chiến lược vector hóa 45
4.5.2 Phân tích khả năng phân cụm – Silhouette Score theo k 46
4.5.3 Phân tích hiệu năng phân loại – ROC và AUC 47

5 Kết luận và định hướng phát triển 49
5.1 Tổng hợp so sánh ba loại dữ liệu 49
5.2 Hạn chế của nghiên cứu 50
5.3 Định hướng nghiên cứu tiếp theo 50

Tài liệu tham khảo 51

Bảng phân công nhiệm vụ

Table 1: Phân công nhiệm vụ và tỷ lệ đóng góp của các thành viên

STT	Họ và tên	MSSV	Nhiệm vụ chính	Đóng góp
1	Nguyễn Hữu Khánh Hưng	23120271	EDA chuyên sâu Phần 1 (ảnh) và Phần 3 (văn bản); thực hiện PCA/t-SNE và Zipf analysis.	100%
2	Phạm Quốc Khánh	23120283	Tiền xử lý ảnh (chuẩn hóa, augmentation) và văn bản (pipeline, tokenization, stop words).	100%
3	Y Nguyên Mlô	23120299	Tiền xử lý ảnh (resize, color space, edge detection) và văn bản (stemming, vector hóa).	100%
4	Vũ Trần Phúc	23120333	Lựa chọn tập dữ liệu bảng; EDA, tiền xử lý và đánh giá định lượng Phần 2.	100%
5	Trần Nguyễn Minh Quân	23120342	Tiền xử lý Phần 2; tổng hợp, viết báo cáo và kiểm tra chéo kết quả.	100%

Tóm tắt điều hành

Tiền xử lý dữ liệu không phải là một bước làm sạch đơn thuần mà là quá trình ra quyết định dựa trên bản chất thống kê của từng loại dữ liệu. Báo cáo này kiểm chứng luận điểm đó qua ba họ dữ liệu đặc trưng, với mọi kết luận được gắn chặt với chỉ số định lượng và kiểm định thống kê có kiểm soát.

Phần 1 – Dữ liệu ảnh số (Intel Image Classification). Sau khi loại 60 ảnh trùng lặp (0,43%) bằng pHash, tập huấn luyện còn 13.974 ảnh với $IR = 1{,}15$ – gần như cân bằng hoàn hảo. Ablation study trên ba kích thước cho thấy SSIM giảm từ 0,80 xuống 0,47 khi thu nhỏ từ 128×128 về 32×32, nhưng accuracy chênh lệch chỉ 0,1% do "PCA bottleneck" tại 200 thành phần. HSV vượt RGB ở k-NN nhờ tách sắc độ khỏi cường độ sáng; GRAY mất $\approx$10% accuracy, xác nhận màu sắc là đặc trưng không thể lược bỏ. t-SNE cho thấy chồng lấp đáng kể giữa các lớp – ranh giới quyết định là phi tuyến, CNN là hướng tất yếu.

Phần 2 – Dữ liệu bảng (Amazon Products Sales). Kiểm định D'Agostino–Pearson bác bỏ phân phối chuẩn ở 6/6 biến ($p \approx 0$, K^2 lên tới 99.590 với `total_reviews`). Little's MCAR Test cho $\chi^2 = 6519{,}55$, $p \approx 0$ [1], buộc dùng k-NN ($k = 10$) và MICE [2] thay vì xóa dòng. Thực nghiệm RMSE trên Ground Truth 30.228 hàng hoàn chỉnh xác nhận k-NN ($k = 10$) đạt RMSE trung bình 2.938,63 – thấp hơn 24,6% so với Mode (3.895,83). Dual-Treatment Pipeline loại 1.115 dòng bất thường qua Majority Voting + Winsorization 1%–99%.

Phần 3 – Dữ liệu văn bản (IMDB Movie Reviews). Tập 50.000 bài [9], cân bằng tuyệt đối, $R^2 = 0{,}9804$ theo Zipf. Sau loại stop words, vocab giảm nhẹ (54.777 $\rightarrow$ 54.625) nhưng Naive Bayes tăng từ 0,8441 lên 0,8625. WordNet Lemmatizer duy trì accuracy 0,8902 trong khi giảm 43% thời gian so với Original Text. TF-IDF [5] Bigram + LinearSVC đạt 89,54%, vượt SBERT [6] (82,34%) khi dùng bộ phân loại tuyến tính.

Pipeline tổng hợp cuối cùng được đề xuất

- **Ảnh số:** 32×32 $\rightarrow$ HSV $\rightarrow$ Z-score per-channel $\rightarrow$ Augmentation $\rightarrow$ CNN.
- **Dữ liệu bảng:** RobustScaler $\rightarrow$ loại `original_price` $\rightarrow$ k-NN/MICE Imputation $\rightarrow$ Dual-Treatment Outlier.
- **Văn bản:** Lowercase $\rightarrow$ Remove HTML $\rightarrow$ Remove Special Chars $\rightarrow$ TF-IDF Bigram (`min_df` $= 5$) $\rightarrow$ LinearSVC.

1. Giới thiệu

1.1 Mục tiêu và câu hỏi nghiên cứu

Tiền xử lý dữ liệu thường bị đơn giản hóa thành chuỗi thao tác cơ học áp dụng đồng nhất cho mọi loại dữ liệu. Đồ án này, thực hiện trong khuôn khổ học phần *Khai thác dữ liệu và ứng dụng* (CSC14004), kiểm chứng ngược lại: mỗi loại dữ liệu có bản chất thống kê riêng đòi hỏi pipeline được thiết kế có chủ đích. Ba câu hỏi nghiên cứu dẫn dắt toàn bộ báo cáo:

1. **(Ảnh số)** Trong số các lựa chọn về kích thước, không gian màu và chuẩn hóa, tổ hợp nào tối ưu chi phí tính toán mà không làm giảm accuracy phân loại đáng kể?
2. **(Dữ liệu bảng)** Khi dữ liệu thiếu không phải MCAR và phân phối lệch nghiêm trọng, chiến lược điền khuyết và phát hiện ngoại lai nào bảo toàn tốt nhất *business signal*?
3. **(Văn bản)** Biểu diễn ngữ nghĩa dày đặc (SBERT) có luôn vượt trội TF-IDF thưa trong phân loại cảm xúc nhị phân?

1.2 Tổng quan tập dữ liệu và cấu trúc báo cáo

Nhóm chọn ba họ dữ liệu có tính bổ sung lẫn nhau: *Intel Image Classification* [8] (14.034 ảnh, 6 lớp cảnh quan ngoài trời), *Amazon Products Sales Dataset 2025* [10] (42.675 sản phẩm điện tử, 17 đặc trưng hỗn hợp) và *IMDB Dataset of 50K Movie Reviews* [9] (50.000 bài, 2 nhãn cảm xúc cân bằng). Lý do EDA chỉ thực hiện trên tập *train*: tránh rò rỉ dữ liệu (data leakage) – nếu phân tích cả tập test, các tham số tiền xử lý (ngưỡng chuẩn hóa, thống kê imputation) sẽ bị "nhiễm" thông tin từ tập đánh giá, khiến kết quả cuối cùng bị thổi phồng.

Phần còn lại: Chương 2 (ảnh số), Chương 3 (dữ liệu bảng), Chương 4 (văn bản), Chương 5 (tổng kết).

2. Tiền xử lý và phân tích dữ liệu ảnh số

Tập dữ liệu Intel Image Classification [8] gồm 6 lớp cảnh quan ngoài trời: *buildings*, *forest*, *glacier*, *mountain*, *sea* và *street*. Toàn bộ pipeline được thiết kế theo hướng *ablation-driven*: mỗi quyết định đều được kiểm định định lượng trước khi kế thừa sang bước tiếp theo.

2.1 Phân tích thống kê tập dữ liệu (EDA)

2.1.1 Phân phối pixel và đặc trưng màu sắc

Quét toàn bộ 14.034 ảnh trên GPU NVIDIA L4 thu được: Red= 109,70, Green= 116,66, Blue= 115,73. Kênh Green và Blue cao hơn Red khoảng 6,96 đơn vị – phản ánh sự chiếm ưu thế của các cảnh quan thiên nhiên (rừng, biển, sông băng) trong tập dữ liệu. Khoảng cách này nhỏ cho thấy tập không bị *color bias* nghiêm trọng, thuận lợi cho quá trình hội tụ của các bộ lọc CNN lớp đầu. Các giá trị trung bình đều hội tụ quanh ngưỡng 110−116, hơi lệch trái so với điểm trung tâm 127,5 – tổng thể tập dữ liệu mang sắc thái trầm, nhiều chi tiết ở vùng tối và trung tính.

Đặc điểm nổi bật trên cả ba kênh màu là hai đỉnh tại giá trị 0 và 255: đỉnh tại 255 do các vùng chói sáng (mây, bầu trời nắng, bề mặt băng tuyết của lớp *glacier*), đỉnh tại 0 do các vùng bóng đổ sâu trong ảnh rừng rậm và đô thị.

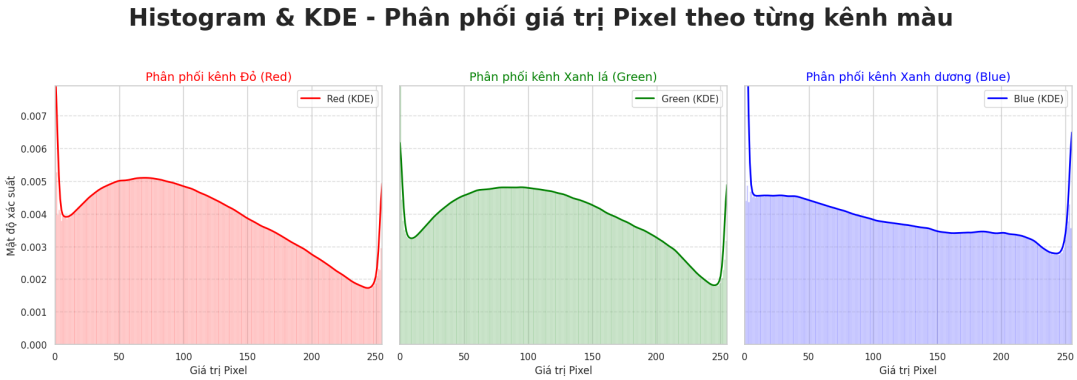

Figure 2.1: Phân phối pixel theo từng kênh màu – tập Intel Image Classification (14.034 ảnh gốc).

Hình 2.1 cần được đọc theo ba lớp thông tin. Thứ nhất, ba đường KDE không "lệch hẳn về một phía" mà phủ gần kín miền $[0, 255]$, xác nhận tập dữ liệu có độ đa

dạng ánh sáng cao thay vì chỉ gồm ảnh ngoài trời sáng gắt. Thứ hai, bụng phân phối của kênh Green phình rộng nhất ở vùng trung tính, phản ánh sự hiện diện lặp lại của thảm thực vật và các bề mặt xanh tự nhiên. Thứ ba, kênh Blue duy trì mật độ đáng kể trên dải rộng hơn kênh Red, cho thấy màu trời, nước và băng xuất hiện trong nhiều trạng thái chiếu sáng khác nhau. Vì vậy, không gian màu không thể bị giản lược quá sớm về Grayscale nếu mục tiêu là giữ tín hiệu nhận dạng lớp.

2.1.2 Phân tích mất cân bằng lớp

Imbalance Ratio $IR = N_{\max}/N_{\min} = 2.512/2.191 = 1{,}15$, thấp hơn nhiều so với ngưỡng cảnh báo $IR > 3$. Tỷ lệ mỗi lớp dao động trong biên độ rất hẹp từ 15,61% (*buildings*) đến 17,90% (*mountain*). Đây là tập cân bằng gần như hoàn hảo: accuracy là metric tin cậy, không cần resampling (SMOTE, undersampling) trước khi huấn luyện.

2.1.3 Phát hiện ảnh trùng lặp bằng pHash và phân tích độ sáng/tương phản theo lớp

Thuật toán pHash (Perceptual Hash) thực hiện qua ba bước: (1) chuyển ảnh về Grayscale và resize về 32×32; (2) áp Biến đổi Cosine Rời rạc (DCT) 2 chiều; (3) so sánh bit của 63 hệ số DCT tần số thấp theo khoảng cách Hamming. Kết quả: phát hiện 60 cặp ảnh trùng lặp tuyệt đối (Hamming = 0), chiếm 0,43% tổng dữ liệu. Tỷ lệ này cực thấp, khẳng định tập Intel có chất lượng thu thập cao, không bị "bơm phồng" bởi copy-paste hàng loạt. Dù chỉ 60 ảnh, việc loại bỏ là bắt buộc để ngăn data leakage nếu ảnh trùng lọt vào cả train và test set.

Phân tích mean intensity theo lớp (Grayscale) cho thấy hai thái cực rõ: *glacier* sáng nhất (mean= 132,49) vì hệ số phản xạ albedo của băng tuyết rất cao; *forest* tối nhất (mean= 85,37) do tán cây che khuất tạo nhiều vùng bóng đổ. Bốn lớp còn lại (*buildings*, *mountain*, *sea*, *street*) có median hội tụ trong dải hẹp 108,64−125,11 – chứng minh "độ sáng" là **đặc trưng yếu** nếu dùng độc lập để phân loại. Mô hình tuyến tính dựa trên phân phối pixel sẽ thất bại với nhóm bốn lớp này; CNN với khả năng học đặc trưng không gian là hướng tất yếu.

Về độ tương phản (standard deviation pixel theo lớp), nhóm đô thị (*street* $\approx$65, *buildings* $\approx$65) cao hơn nhóm thiên nhiên (*forest* $\approx$53, *sea* $\approx$53) – phản ánh đường nét sắc bén của kính phản quang, góc bê tông đô thị so với sự đồng nhất của thảm lá rừng hay mặt nước. Một nghịch lý thú vị: *glacier* là lớp *sáng nhất* nhưng lại có độ tương phản *thấp* ($\approx$55,9) vì khi toàn bộ pixel gần giá trị 255 (tuyết trắng), phương sai tất

nhiên giảm.

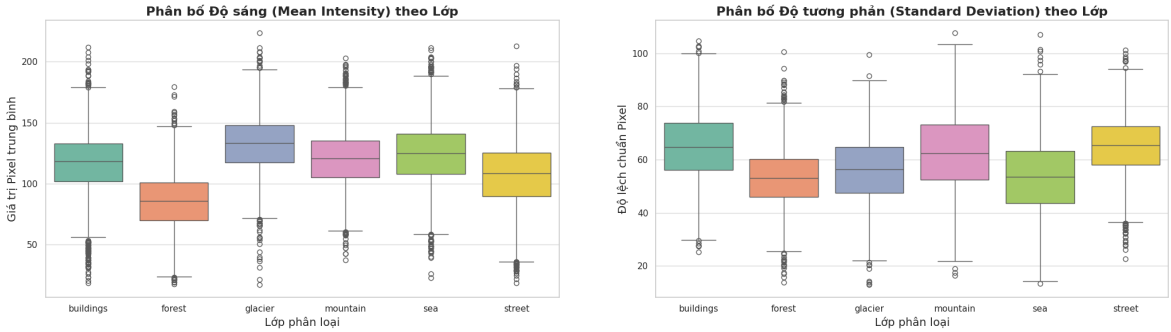

(a) Mean intensity theo lớp. **(b)** Standard deviation theo lớp.

Figure 2.2: Phân bố độ sáng (mean intensity) và độ tương phản (std) theo lớp – tập Intel 13.974 ảnh sạch.

Nếu đọc kỹ Hình 2.2, có thể thấy khoảng cách giữa hai cực *forest–glacier* là rõ ràng ở median nhưng phần IQR của bốn lớp còn lại chồng lấp rất mạnh. Điều này giải thích vì sao các mô hình dựa trên vài thống kê toàn cục khó đạt accuracy cao: cùng một mức sáng trung bình, ảnh *sea* và *mountain* có thể khác nhau hoàn toàn về cấu trúc không gian. Ở boxplot độ tương phản, số lượng outlier hai phía cũng rất quan trọng: các outlier sáng trong *forest* thường là ảnh có tia nắng xuyên tán lá, còn outlier tương phản thấp của *street* thường đến từ ảnh mờ, sương hoặc khung hình chỉ chứa mặt đường. Vì vậy, chuẩn hóa và augmentation về độ sáng/tương phản là bước hỗ trợ cần thiết, nhưng không thể thay thế trích xuất đặc trưng không gian.

2.2 Thay đổi kích thước ảnh – SSIM, PSNR và Ablation Study

2.2.1 Mức độ mất mát thông tin (SSIM và PSNR)

Để đo lượng thông tin bị mất khi thu nhỏ, ảnh được resize xuống kích thước đích rồi *upscale ngược* lên 150×150 để so sánh với gốc. Kết quả trên 13.974 ảnh (GPU NVIDIA L4):

Table 2.1: Mức độ mất mát thông tin theo kích thước ảnh – SSIM và PSNR
Đánh giá so với ảnh gốc 150×150 *bằng cách upscale ảnh đã resize ngược lên* 150×150. *Ngưỡng chấp nhận PSNR:* $>$ 20 *dB.*

Kích thước	**Mean SSIM**	**Mean PSNR (dB)**	**Phân tích**
32×32	0,47	19,57	SSIM dưới 0,5: cấu trúc bị phá vỡ nghiêm trọng; PSNR dưới 20 dB. Mô hình khó nhận diện hình dạng vật thể ban đầu.
64×64	0,62	21,21	PSNR vượt 20 dB; các khối cấu trúc lớn (hình dáng núi, dải đường phố) vẫn nhận ra được, chi tiết nhỏ bắt đầu mờ.
128×128	0,80	23,56	Giữ lại ≈80% cấu trúc; hầu hết chi tiết cảnh quan (ô cửa sổ, gợn sóng, rãnh băng) bảo toàn tốt.

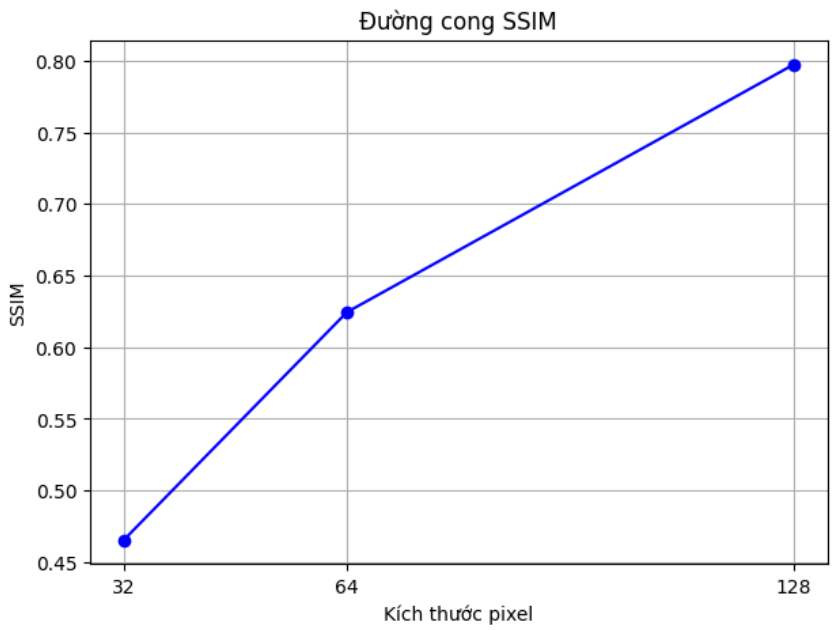

Figure 2.3: Đường cong SSIM theo kích thước resize.

Hình 2.3 cho thấy SSIM tăng đơn điệu theo kích thước resize: mỗi bước tăng độ phân giải đều phục hồi thêm cấu trúc không gian, nhưng lợi ích biên giảm dần khi đi từ 64×64 lên 128×128.

Phân tích theo chỉ số SSIM

- 128×128 **(SSIM $\approx$0,80).** Mức độ giữ lại cấu trúc đạt gần 80%. Vì kích thước này vẫn rất gần với ảnh gốc, hầu hết cấu trúc không gian và chi tiết cảnh quan như góc cạnh tòa nhà, gợn sóng biển hay tán cây được bảo toàn tốt. Ảnh hầu như không biến dạng về mặt tổng thể; cả mắt người lẫn mô hình học máy vẫn nhận ra khá rõ các chi tiết nhỏ như ô cửa sổ hay rãnh nứt trên bề mặt băng của lớp *glacier*.
- 64×64 **(SSIM $\approx$0,62).** Mức độ tương đồng cấu trúc bắt đầu giảm rõ rệt. Các chi tiết nhỏ như viền lá cây hoặc gợn sóng đã bị làm mờ, nhưng các khối cấu trúc lớn như đường chân núi, đường phân cách mặt biển–bầu trời hay bố cục tổng thể của cảnh *street* vẫn được giữ lại đủ tốt để tạo tín hiệu cho bộ phân loại.
- 32×32 **(SSIM $\approx$0,47).** Giá trị SSIM rơi xuống dưới 0,5, báo hiệu cấu trúc không gian đã suy giảm nghiêm trọng. Ảnh trở nên vỡ và mờ rõ rệt; các chi tiết nhỏ hòa lẫn vào nhau, khiến mô hình khó phục hồi hình dáng vật thể ban đầu nếu chỉ dựa trên đặc trưng thị giác thô.

Phân tích theo chỉ số PSNR

- 128×128 **(23,56 dB) và** 64×64 **(21,21 dB).** PSNR vẫn duy trì trên ngưỡng 20 dB, tức là "tín hiệu" hữu ích của ảnh vẫn áp đảo sai số do resize. Dù đã xuất hiện một số sai lệch màu sắc cục bộ, phân bố màu tổng thể và các vùng tương phản chính vẫn còn đủ ổn định để hỗ trợ phân loại.
- 32×32 **(19,57 dB).** PSNR rơi xuống dưới 20 dB. Ở mức này, hiện tượng color blending giữa các pixel lân cận diễn ra mạnh: màu xanh của *forest* hoặc *sea* dễ bị pha trộn với vùng xám của *street* và *buildings*, làm suy giảm tính đại diện của histogram màu và giảm khả năng tách lớp bằng đặc trưng màu đơn giản.

Nhận xét tổng quát

Hai chỉ số SSIM và PSNR cùng cho thấy sự đánh đổi rõ ràng giữa chi phí tính toán và độ trung thực thông tin. Kích thước 128×128 bảo toàn dữ liệu tốt nhất, nhưng số chiều đầu vào tăng mạnh nên RAM và thời gian PCA/huấn luyện cũng đội lên nhiều lần. Ngược lại, 32×32 giúp rút từ 22.500 xuống chỉ còn 1.024 pixel, tối ưu chi phí nhưng đánh đổi bằng việc mất nhiều manh mối trực quan ở mức tiền xử lý.

Nếu chỉ xét riêng chất lượng tín hiệu đầu vào, 64×64 là điểm cân bằng hợp lý: số pixel giảm khoảng 81,8% so với ảnh gốc 150×150 (22.500 xuống 4.096), trong khi

SSIM vẫn vượt ngưỡng 0,6 và PSNR còn trên 20 dB.

2.2.2 Ablation Study – Tác động kích thước đến accuracy phân loại

Pipeline: Load uint8 (150×150) → Resize → Flatten/255 → PCA (200 thành phần, randomized) → k-NN ($k = 5$) và LR (lbfgs).

Table 2.2: Ablation Study – kích thước ảnh vs. accuracy phân loại
Tập test: 3.000 ảnh (Intel seg_test). PCA bottleneck tại 200 thành phần áp dụng đồng nhất.

Kích thước	**k-NN Acc**	**LR Acc**	**RAM (MB)**	**Thời gian PCA**	**Số chiều**	**Nhận xét**
32×32	51%	53%	172	7,7 giây	3.072	Tối ưu: chi phí thấp nhất, accuracy tương đương.
64×64	51%	53%	687	19,2 giây	12.288	Chấp nhận được.
128×128	51%	54%	2.747	69 giây	49.152	Chi phí cao, lợi ích biên thấp.
150×150	51%	54%	3.773	90,8 giây	67.500	Không hiệu quả với mô hình tuyến tính.

Kết quả cho thấy hai điểm đáng chú ý:

- Thứ nhất, LR luôn vượt k-NN ở mọi kích thước (khoảng 2−3%) vì LR học được trọng số tối ưu cho từng chiều đặc trưng, trong khi k-NN dựa trên khoảng cách Euclidean thuần túy – kém hiệu quả trong không gian ảnh nhiều nhiễu.
- Thứ hai, accuracy gần như "đi ngang" khi tăng kích thước: LR đạt đỉnh ≈54% ở 150×150 nhưng ở 32×32 đã đạt ≈53%, chênh lệch chỉ ≈1%. Nguyên nhân là "PCA Bottleneck": dù đầu vào có 3.072 hay 67.500 chiều, tất cả đều bị nén về đúng 200 thành phần trước khi vào classifier. 200 thành phần chính này đã bão hòa lượng thông tin phân loại mà hai mô hình tuyến tính có thể khai thác. Tăng độ nét ảnh ban đầu không cung cấp thêm thông tin lọt qua được "bộ lọc" PCA 200 chiều.

Đây là tình huống mà SSIM/PSNR và ablation study cho thấy *phương hướng ngược nhau*: về chất lượng tín hiệu, 128×128 tốt hơn 32×32 đáng kể; nhưng về accuracy phân loại với mô hình tuyến tính, hai kích thước tương đương nhau. Kết luận phụ thuộc vào mục tiêu: nếu dùng CNN (không có PCA), ảnh lớn hơn sẽ có lợi hơn.

Kết luận lựa chọn

Kích thước được chọn: **32×32**. Lý do: chi phí RAM giảm 22× và PCA nhanh hơn 13× so với 150×150, trong khi accuracy không suy giảm đáng kể khi dùng PCA. Với CNN, kích thước 64×64 là hướng thử nghiệm hợp lý hơn.

2.3 Chuyển đổi không gian màu

2.3.1 Đo lường phương sai giải thích – PCA $k = 50$

Table 2.3: Phương sai giải thích với PCA $k = 50$ theo không gian màu
Kích thước 32×32. *Phương sai giải thích* $= \sum_{i=1}^{50} \lambda_i / \sum_{j=1}^{d} \lambda_j$.

Không gian màu	**Phương sai giải thích** ($k = 50$)	**Thời gian PCA**	**Giải thích**
GRAY	85,82%	≈6 giây	Một kênh ⇒ PCA tập trung hình khối và tương phản sáng tối. Tuy nhiên mất hoàn toàn thông tin sắc độ.
RGB	84,82%	≈12 giây	Ba kênh tương quan cao ⇒ PCA dễ trích xuất principal components.
LAB	83,97%	≈13 giây	Tách L (sáng) khỏi a/b (màu), nhưng phân phối kênh a/b kém đồng nhất hơn HSV.
HSV	81,68%	≈14 giây	Phương sai giải thích thấp nhất nhưng không đồng nghĩa chất lượng kém.

Điểm then chốt: GRAY dẫn đầu về phương sai giải thích vì với một kênh duy nhất, PCA không bị phân tán tài nguyên nén ba kênh độc lập. Tuy nhiên phương sai giải thích cao *không đồng nghĩa* với giá trị phân biệt (discriminative value) cao – kết quả ablation study bên dưới sẽ làm rõ điều này.

2.3.2 Ablation Study – Tác động không gian màu đến accuracy

Table 2.4: Ablation Study – không gian màu vs. accuracy phân loại
Kích thước 32×32, *PCA* $k = 50$ *cố định; tập test Intel 3.000 ảnh.*

Không gian màu	**k-NN Acc**	**LR Acc**	**T.gian LR**	**Nhận xét**
RGB	53%	55%	1,49 giây	Cấu hình cơ sở
GRAY	45%	43%	1,26 giây	Loại bỏ – mất ≈10% accuracy
HSV	**55%**	53%	2,04 giây	**Lựa chọn** – k-NN cao nhất
LAB	53%	**55%**	1,36 giây	Tốt với LR

Kết quả bác bỏ trực giác thông thường rằng "nhiều thông tin hơn thì phân loại tốt hơn". GRAY giữ nhiều phương sai nhất (85,82%) nhưng mất ≈10% accuracy vì loại bỏ hoàn toàn thông tin sắc độ – đặc trưng định danh cốt lõi của cảnh quan tự nhiên. Khi một mảng pixel màu xanh lục gần như chắc chắn là rừng và màu xanh lam là biển, xóa thông tin màu làm cho núi đá xám và rừng rậm trở nên không phân biệt được qua kết cấu bề mặt.

HSV đạt k-NN cao nhất (55%) dù phương sai giải thích thấp nhất (81,68%). Điều này xác nhận rằng phần phương sai "mất đi" trong HSV chủ yếu là nhiễu chiếu sáng (illumination noise). Bằng cách cô lập kênh Value (V) khỏi Hue (H) và Saturation (S), HSV giúp mô hình "nhìn xuyên" qua sự thay đổi ánh sáng để nhận diện màu sắc đặc trưng của từng lớp cảnh quan. LAB mang ý nghĩa vật lý tương tự nhưng phân phối kênh a/b kém đồng nhất hơn, dẫn đến hiệu năng thấp hơn HSV ở k-NN.

Nghịch lý PCA – Phương sai cao ≠ Phân loại tốt: Đối chiếu Explained Variance với kết quả accuracy cho thấy một nghịch lý rõ nét. GRAY bảo toàn nhiều phương sai nhất (85,82%) nhưng cho kết quả phân loại tệ nhất; HSV mất nhiều phương sai nhất (81,68%) lại đạt accuracy cao nhất ở k-NN (55%). Lý giải: phương sai mà PCA cố giữ lại đơn thuần là "sự biến thiên của dữ liệu" – hoàn toàn có thể là nhiễu chiếu sáng (bóng râm, cường độ sáng). Khi PCA xử lý GRAY hoặc RGB, nó ưu tiên giữ các biến thiên ánh sáng vô bổ này. Ngược lại, vì HSV đã bóc tách ánh sáng trước, 50 PC của HSV tuy mang tổng phương sai nhỏ hơn nhưng là thông tin màu sắc "sạch", trực tiếp phục vụ định danh nhãn lớp. k-NN ưa HSV vì khoảng cách trong không gian Hue tạo cụm màu chặt; LR ưa LAB vì phân phối tuyến tính của các trục a^*/b^* hỗ trợ tối ưu siêu phẳng phân tách.

Kết luận lựa chọn

Không gian màu được chọn: **HSV**. Lý do: tách sắc độ khỏi cường độ sáng, giúp mô hình bất biến trước thay đổi điều kiện chiếu sáng (góc nắng, mùa trong năm). Z-score per-channel sẽ chuẩn hóa độc lập ba kênh $H/S/V$ – quan trọng vì ba kênh này có đơn vị hoàn toàn khác nhau.

2.4 Chuẩn hóa pixel – Kiểm định KS và Ablation Study

Chuẩn hóa phục vụ hai mục tiêu: ổn định gradient descent cho CNN (tránh bùng nổ gradient khi đầu vào ở miền $[0, 255]$) và cân bằng đóng góp giữa các đặc trưng cho k-NN/SVM (nếu một kênh có miền $[0, 255]$ và kênh khác $[0, 1]$, kênh đầu sẽ chi phối khoảng cách Euclidean hoàn toàn). Bốn phương pháp được so sánh:

Table 2.5: So sánh các chiến lược chuẩn hóa pixel – KS test và accuracy
KS test: so sánh CDF trước và sau chuẩn hóa; H_0: hai phân phối như nhau. Tập Intel 13.974 ảnh, 32×32, HSV.

Phương pháp	**Phạm vi**	**KS stat (D)**	**k-NN Acc**	**LR Acc**	**Nhận xét**
Gốc	$[0, 255]$	—	53%	52%	Cơ sở
Min-Max $[0, 1]$	$[0, 1]$	0,95	53%	52%	Tương đương gốc
Min-Max $[-1, 1]$	$[-1, 1]$	0,95	53%	52%	Tương đương gốc
Z-score Global	$(-1,35;\ 2,46)$	0,95	53%	52%	Tương đương gốc
Z-score Per-channel	$(-1,88;\ 2,81)$	0,95	53%	52%	**Lựa chọn**

Tất cả phương pháp đều có p-value ≈ 0 (KS stat $D = 0{,}95$) – chuẩn hóa thay đổi phân phối pixel có ý nghĩa thống kê (dịch chuyển CDF cực lớn). Tuy nhiên đây là phép biến đổi tuyến tính: không thay đổi thứ tự khoảng cách giữa các điểm, do đó k-NN và LR không cải thiện accuracy. Từ góc độ thực nghiệm, lựa chọn giữa các phương pháp không dựa vào ablation study (vì kết quả giống nhau) mà dựa vào ba lý do kỹ thuật của Z-score per-channel: (i) chuẩn hóa độc lập ba kênh $H/S/V$ vốn có đơn vị khác nhau – hue tính bằng độ $[0, 360]$, saturation và value trong $[0, 1]$; (ii) tương thích chuẩn ImageNet pre-training ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$); (iii) triệt tiêu color bias còn sót lại sau bước chuyển không gian màu.

Kết luận lựa chọn

Chuẩn hóa được chọn: **Z-score per-channel**. Quyết định này dựa trên tính tương thích deep learning và tính đúng đắn về đơn vị giữa các kênh HSV, không phải vì cải thiện ablation study với mô hình tuyến tính.

2.5 Tăng cường dữ liệu – Data Augmentation

Sau khi cố định kích thước 32×32, không gian màu HSV và chuẩn hóa Z-score per-channel, nhóm tiếp tục thực hiện thêm một bước *data augmentation* riêng cho tập huấn luyện. Mục tiêu của bước này không phải tạo ra "ảnh mới" theo nghĩa ngữ nghĩa,

mà là sinh các biến thể hình học và quang học vẫn giữ nguyên nhãn để tăng tính bất biến của mô hình trước thay đổi góc chụp, ánh sáng và nhiễu sensor. Vì dữ liệu Intel là ảnh cảnh quan ngoài trời, augmentation đặc biệt hữu ích cho CNN: mô hình buộc phải học cấu trúc cảnh quan thay vì ghi nhớ bố cục pixel cụ thể của từng ảnh.

Pipeline augmentation trong notebook áp dụng tuần tự sáu phép biến đổi với xác suất độc lập:

- **Lật ngang** với $p = 0{,}5$: phù hợp vì phần lớn cảnh quan vẫn hợp lệ khi đối xứng trái–phải.
- **Lật dọc** với $p = 0{,}3$: dùng xác suất thấp hơn vì ảnh bị đảo ngược hoàn toàn hiếm gặp trong thực tế.
- **Xoay** với góc $\theta \sim \mathcal{U}(-30°, 30°)$: mô phỏng lệch góc máy ảnh khi chụp thực địa.
- **Random Crop** với tỉ lệ cắt $r \sim \mathcal{U}(0{,}80, 1{,}0)$ rồi resize về kích thước gốc: mô phỏng zoom-in và buộc mô hình nhận diện lớp từ vùng cục bộ.
- **Gaussian Noise** với $\sigma \sim \mathcal{U}(0, 15)$: mô phỏng nhiễu cảm biến trong điều kiện ánh sáng kém.
- **Điều chỉnh sáng/tương phản** theo $x' = \alpha x + \beta$, với $\alpha \sim \mathcal{U}(0{,}7, 1{,}3)$ và $\beta \sim \mathcal{U}(-30, 30)$: mô phỏng thay đổi cường độ chiếu sáng theo thời điểm trong ngày.

Trong cài đặt thực nghiệm, mỗi ảnh gốc sinh đúng một ảnh augmented, nên kích thước tập train tăng gấp đôi mà không cần đọc lại từ đĩa. Đây là lựa chọn hợp lý về chi phí: đủ để "làm dày" mật độ mẫu huấn luyện nhưng chưa tạo gánh nặng lưu trữ quá lớn. Tuy nhiên, augmentation chỉ có giá trị nếu nó không làm lệch phân phối dữ liệu quá mạnh. Kết quả trong notebook cho thấy histogram HSV giữa tập gốc và tập augmented có dịch chuyển nhưng vẫn giữ hình dạng tổng thể; KS statistic lớn nhất nằm ở kênh Hue ($\approx 0{,}137$), còn hai kênh Saturation và Value chỉ ở mức $\approx 0{,}03 - 0{,}04$. Nói cách khác, augmentation có tác động thống kê rõ ràng nhưng chưa gây *distribution shift* cực đoan.

Phân tích ở mức không gian đặc trưng cũng đưa ra kết luận tương tự. Như Hình 2.5 cho thấy ở phần sau, các điểm augmented chồng lấp gần như hoàn toàn với tập gốc trong không gian t-SNE. Đây là dấu hiệu tốt vì augmentation đang tạo ra các biến thể "hợp lệ" nằm trong cùng manifold dữ liệu, thay vì sinh ra cụm ảnh xa lạ mà mô hình sẽ không gặp khi triển khai thực tế. Tuy nhiên, chính sự chồng lấp gần như hoàn toàn này cũng ngụ ý một giới hạn: augmentation hiện tại còn khá "an toàn", chủ yếu thêm nhiễu nhẹ chứ chưa mở rộng rõ rệt representation space của dữ liệu ảnh.

Table 2.6: Ablation Study – tác động của augmentation lên mô hình tuyến tính
So sánh train trên tập gốc và train trên tập gốc + 1 bản augmented cho mỗi ảnh.

Thiết lập train	**k-NN**	**Logistic Regression**	**Nhận xét**
Chỉ dùng ảnh gốc	0,50	0,52	Mốc tham chiếu.
Ảnh gốc + augmented	0,51	0,50	k-NN tăng rất nhẹ, LR giảm nhẹ.

Kết quả ở Bảng 2.6 khá quan trọng về mặt diễn giải. k-NN tăng nhẹ khoảng +0,01, cho thấy augmentation có thể giúp "làm dày" lân cận cục bộ trong không gian đặc trưng. Ngược lại, Logistic Regression giảm khoảng −0,02, tức là các phép biến đổi hiện tại chưa tạo thêm tín hiệu phân biệt tuyến tính mà chủ yếu làm mờ bớt ranh giới siêu phẳng. Vì vậy, augmentation trong cấu hình hiện tại **không thực sự cải thiện mô hình tuyến tính**; giá trị lớn nhất của nó nằm ở việc chuẩn bị dữ liệu cho các mô hình phi tuyến như CNN, nơi tính bất biến hình học và quang học quan trọng hơn nhiều.

Kết luận lựa chọn

Augmentation được **giữ lại** trong pipeline cuối cùng, nhưng vai trò chính là hỗ trợ **CNN/transfer learning**, không phải tối ưu k-NN hay Logistic Regression. Cấu hình hiện tại đủ an toàn để tăng đa dạng mẫu mà không phá vỡ manifold dữ liệu, song vẫn còn dư địa để mở rộng sang augmentation mạnh hơn hoặc mang tính semantic.

2.6 [Nâng cao] Phân tích PCA và t-SNE – Cấu trúc không gian đặc trưng

Table 2.7: Ngưỡng phương sai tích lũy và số thành phần PCA
Tập Intel 13.974 ảnh, 32×32, HSV, Z-score per-channel. Tổng số chiều: 32×32×3 = 3.072.

Ngưỡng phương sai	Số thành phần	Tỷ lệ nén	Nhận định
90%	385	8,0×	Gần elbow point; loại bỏ nhiễu bậc cao, tối ưu cho k-NN.
95%	892	3,4×	Sweet spot – cân bằng giữa nén dữ liệu và bảo toàn thông tin.
99%	1.956	1,6×	Tỷ lệ nén thấp, giữ lại nhiều nhiễu tần số cao.

Đồ thị phương sai tích lũy có độ dốc rất lớn ở những PC đầu tiên (PC_1 đơn lẻ đã giải thích > 20% phương sai) – minh chứng cho sự tồn tại của tính dư thừa thông tin (information redundancy) rất lớn trong ảnh pixel thô. Các điểm ảnh lân cận trong ảnh cảnh quan tự nhiên có tương quan cực cao về sắc độ và độ sáng, PCA thành công trong việc nén các tương quan này vào không gian vector nhỏ hơn.

Phân tích PCA 2D (PC_1+PC_2 giải thích 36,34% phương sai) cho thấy cấu trúc "đám mây hỗn hợp": lớp *forest* tương đối tách biệt ở phía trên bên trái (nhờ tính đồng nhất cao về Hue và Saturation của thảm thực vật), trong khi *glacier–mountain–sea* tạo thành dải phổ liên tục ở vùng trung tâm (do tông màu trắng-xám-lam tương đồng nhau). Nhóm đô thị (*buildings*, *street*) chồng lấp nhiều với các lớp khác.

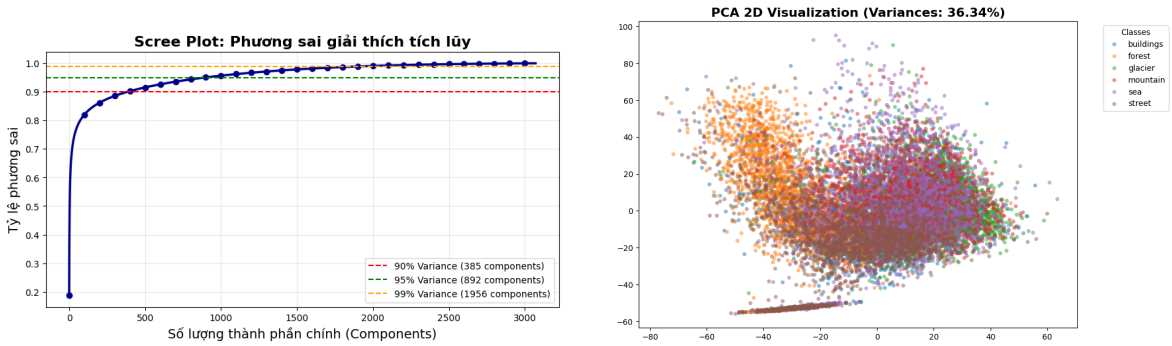

(a) Scree plot. **(b)** PCA 2D scatter theo lớp.

Figure 2.4: Scree Plot và PCA 2D – tập Intel 13.974 ảnh (32×32, HSV, Z-score per-channel). PC_1+PC_2 giải thích 36,34% phương sai.

Hình 2.4 làm rõ hai kết luận khác nhau. Scree plot cho thấy phần lớn thông tin màu và cường độ được nén vào một số lượng thành phần chính hữu hạn; sau ngưỡng đó, mỗi PC bổ sung chỉ mang lại lợi ích biên rất nhỏ. Đây là cơ sở của nhận định "PCA bottleneck" trong ablation study: tăng kích thước ảnh không tự động làm tăng accuracy nếu pipeline cuối cùng vẫn nén về số PC cố định. Tuy nhiên, scatter PCA 2D đồng thời cho thấy cụm lớp vẫn không tách tuyến tính sạch. Nói cách khác, PCA nén dữ liệu hiệu quả theo nghĩa phương sai, nhưng phương sai lớn nhất không đồng nghĩa với trục phân biệt lớp tốt nhất.

Phân tích t-SNE [4] (3.000 mẫu phân tầng, perplexity= 40, thời gian 268,05 giây) cho thấy cấu trúc chi tiết hơn PCA. Lớp *forest* hội tụ thành một dải tập trung rõ rệt ở phía phải biểu đồ. Lớp *street* xuất hiện một "đảo biệt lập" ($y \approx 120$) – nhóm ảnh có bão hòa màu cực cao hoặc cấu trúc hình học lặp lại mạnh mà phép chiếu tuyến tính PCA bỏ lỡ. Tuy nhiên, vùng trung tâm vẫn duy trì "vùng hỗn hợp đa lớp" giữa *glacier*, *mountain*, *sea* và một phần *buildings* – bằng chứng của *semantic gap*: ngay cả với thuật toán phi tuyến mạnh như t-SNE, thông tin HSV pixel thô chưa đủ để phân biệt các lớp ngữ nghĩa gần nhau. Ranh giới quyết định là phi tuyến và phức tạp; CNN là hướng đi cần thiết.

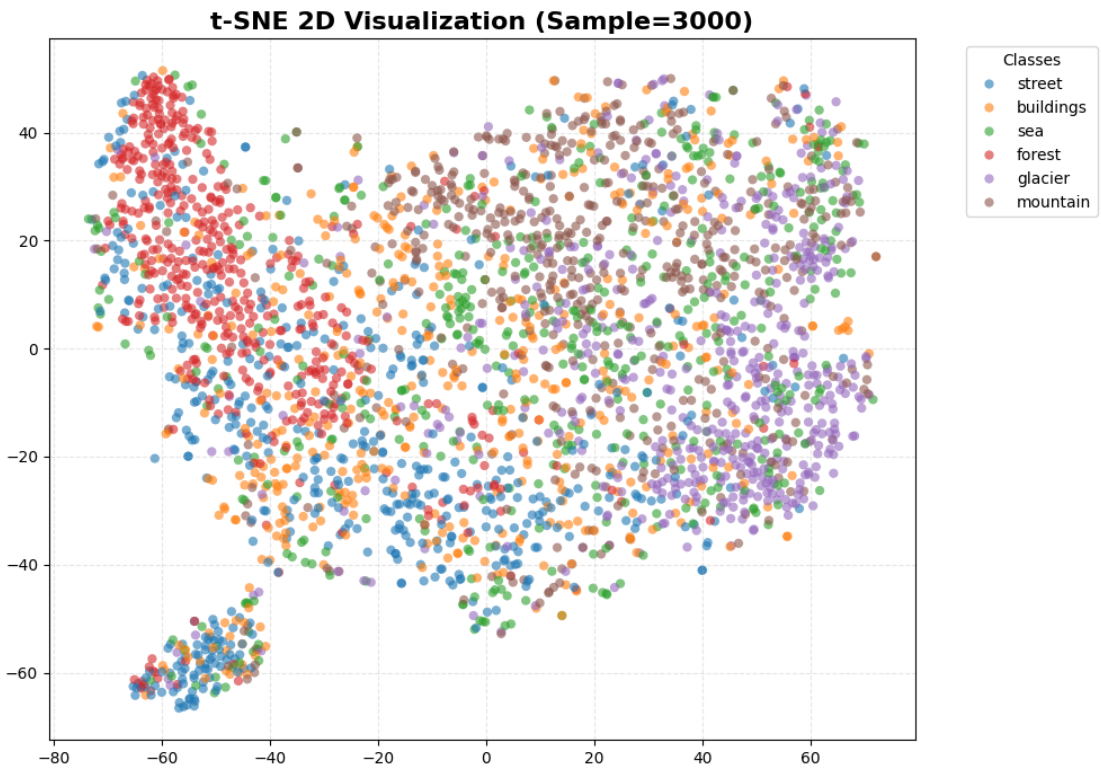

Figure 2.5: t-SNE 2D – tập Intel 3.000 mẫu phân tầng (perplexity= 40, 268,05 giây). Augmented samples nằm trong cùng manifold với dữ liệu gốc.

Hai nửa của Hình 2.5 trả lời hai câu hỏi khác nhau về tiền xử lý. Ở phép tô màu

"gốc vs. augmented", sự chồng lấp gần hoàn toàn cho thấy augmentation đang tạo biến thể "hợp lệ" của dữ liệu thay vì sinh ra phân phối lạ. Đây là tín hiệu tốt cho huấn luyện CNN, vì mô hình nhìn thấy thêm nhiễu có kiểm soát mà không bị lệch miền. Ở phép tô màu theo nhãn, *forest* tách rõ nhất nhờ tính đồng nhất về hue, còn *glacier*, *sea* và *mountain* tiếp tục quấn vào nhau ở lõi trung tâm. Như vậy, augmentation giúp tăng độ bền vững của mô hình, nhưng không giải quyết tận gốc bài toán chồng lấp ngữ nghĩa nếu đặc trưng đầu vào vẫn chỉ là pixel-level representation.

Augmentation tạo ra dịch chuyển phân phối có kiểm soát (KS test $p \approx 0$, stat kênh H$\approx$0,137, kênh S và V$\approx$0,03$-$0,04) nhưng không mở rộng đáng kể không gian đặc trưng – hai tập gốc và augmented chồng lấp gần như hoàn toàn trong t-SNE. Đây vừa là kết quả tốt (augmentation không gây distribution shift lớn) vừa là tín hiệu cần chú ý (mức độ biến đổi còn "an toàn", chưa tạo ra representation mới đủ phong phú để cải thiện accuracy đáng kể).

2.7 [Nâng cao] Phát hiện cạnh – Edge Detection và ANOVA

Table 2.8: So sánh các kỹ thuật phát hiện cạnh – ANOVA một chiều kiểm định Edge Density theo lớp
H_0: các lớp có Edge Density trung bình bằng nhau. F-statistic lớn hơn thể hiện khả năng phân biệt lớp tốt hơn. Tham chiếu: Canny [3].

Phương pháp	**F-statistic**	**p-value**	**Kết luận ANOVA**	**Nhận xét**
Sobel ($k = 3$)	591,17	$\approx$0	Bác bỏ H_0	Tốt
Sobel ($k = 5$)	365,78	$\approx$0	Bác bỏ H_0	Yếu hơn do làm mờ
Prewitt (chuẩn)	570,36	$\approx$0	Bác bỏ H_0	Tốt
Prewitt (blurred)	357,34	$\approx$0	Bác bỏ H_0	Yếu hơn
Canny (100, 200)	1.713,29	$\approx$0	Bác bỏ H_0	Tốt
Canny (50, 150)	**1.865,95**	$\approx$0	Bác bỏ H_0	**Lựa chọn**

Tất cả 6 cấu hình đều bác bỏ H_0 với $p \approx 0$: thông tin cạnh có khả năng phân biệt thống kê giữa các lớp. Canny $(50, 150)$ [3] dẫn đầu với $F = 1.865{,}95$ vì ngưỡng thấp bắt được cả cạnh mờ như gợn sóng biển và cấu trúc mây. Thứ tự mật độ cạnh: *forest* ($\approx$0,35) > *street* ($\approx$0,30) > *buildings* ($\approx$0,27) > *glacier* ($\approx$0,23) > *mountain/sea* ($\approx$0,20). Kết quả này có giải thích vật lý rõ ràng: rừng tạo ra vô số viền cạnh nhỏ từ

lá và cành nhánh; đô thị có đường nét nhân tạo sắc bén; sông băng và núi khi resize về độ phân giải thấp mất chi tiết bề mặt, chỉ còn đường chân trời. Tuy nhiên, boxplot vẫn cho thấy chồng lấp đáng kể giữa các cặp *mountain/sea* và *buildings/street*: Edge Density chỉ là *đặc trưng bổ trợ*, cần kết hợp với Color Histogram, GLCM hoặc LBP.

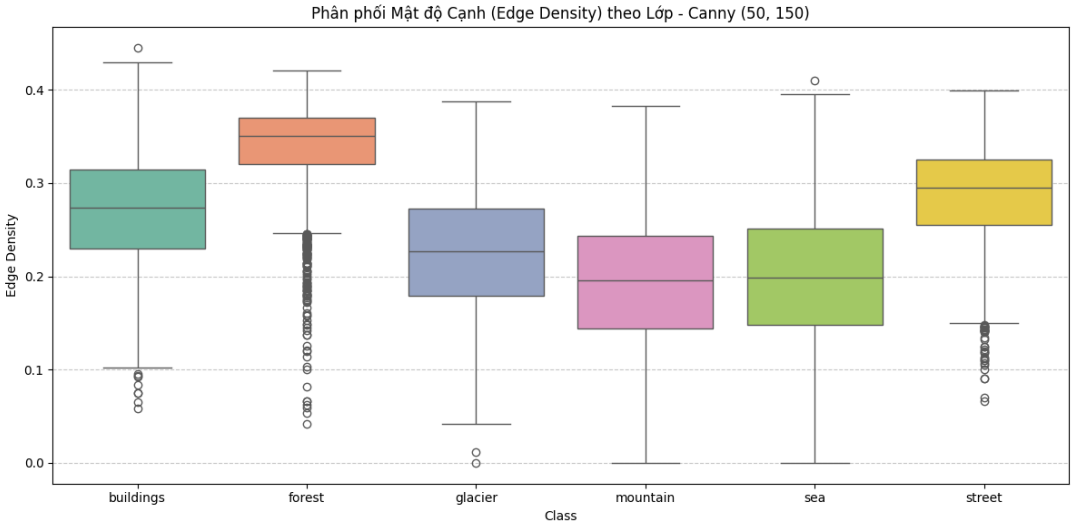

Figure 2.6: Edge Density theo lớp – so sánh 6 phương pháp phát hiện cạnh. Canny $(50, 150)$ cho $F = 1.865{,}95$ cao nhất.

Giá trị của Hình 2.6 không nằm ở việc "phương pháp nào cao nhất" mà ở chỗ nó chỉ ra loại tín hiệu nào đang được bắt. Với Canny $(50, 150)$, median của *forest* và *street* đều cao nhưng bản chất khác nhau: *forest* tạo ra biên dày đặc, nhỏ và phân mảnh; *street* tạo ra biên dài, sắc và có hướng tính cao. Do boxplot Edge Density chỉ đo tổng lượng cạnh chứ chưa mô tả hình học của cạnh, nó tách tốt nhóm "ít cạnh" và "nhiều cạnh" nhưng chưa đủ để phân rã hoàn toàn các lớp gần nhau. Vì vậy, edge feature nên được xem là đặc trưng bổ trợ cho texture và color, không phải tín hiệu đơn lẻ để phân loại cuối cùng.

Kết luận Phần 1 – Pipeline tối ưu cho dữ liệu ảnh

- **Kích thước:** 32×32 – RAM giảm $22\times$, PCA nhanh hơn $13\times$, accuracy tương đương ($\pm 0{,}7\%$) với mô hình tuyến tính.
- **Không gian màu:** HSV – tách sắc độ khỏi cường độ sáng, bất biến với điều kiện chiếu sáng.
- **Chuẩn hóa:** Z-score per-channel – tương thích deep learning, chuẩn hóa đúng đơn vị giữa $H/S/V$.
- **Augmentation:** flip ngang/dọc, rotation, random crop, Gaussian noise, bright-

ness/contrast – augmented samples nằm trong cùng manifold với dữ liệu gốc (t-SNE chồng lấp).

- **Edge detection:** Canny $(50, 150)$ – $F = 1.865{,}95$, cao nhất trong 6 phương pháp.
- **Accuracy tốt nhất** với k-NN/LR: $\approx 55\%$. Ranh giới quyết định phi tuyến; **CNN (LeNet-5, ResNet-50) + transfer learning ImageNet** là hướng tiếp theo.

3. Tiền xử lý và phân tích dữ liệu bảng

Tập Amazon Products Sales Dataset 2025 [10] gồm 42.675 sản phẩm điện tử / 17 đặc trưng hỗn hợp. Đây là môi trường dữ liệu điển hình của thương mại điện tử: phân phối lệch nghiêm trọng, nhiều cơ chế thiếu khác nhau, và ngoại lai thường mang ý nghĩa nghiệp vụ (bán viral, chiến dịch giảm giá) chứ không phải nhiễu thuần túy.

3.1 Phân tích phân phối – Kiểm định D'Agostino–Pearson

Với cỡ mẫu $n > 5.000$, nhóm sử dụng kiểm định D'Agostino–Pearson thay vì Shapiro–Wilk. Lý do: Shapiro–Wilk có sensitivity quá cao khi n lớn, dễ dẫn đến tăng Type I Error – tức là bác bỏ H_0 (phân phối chuẩn) ngay cả khi lệch rất nhỏ không có ý nghĩa thực tiễn. D'Agostino–Pearson dựa trên skewness và kurtosis, phản ánh đúng hình dạng phân phối hơn.

Table 3.1: Đánh giá phân phối của 6 biến số và scaler đề xuất
H_0: phân phối chuẩn. Cỡ mẫu sau dropna: từ 32.164 đến 41.651 bản ghi.

Biến số	**Skewness**	**Kurtosis**	K^2	p**-value**	**Scaler đề xuất**
`total_reviews`	24,34	Rất cao	$\approx$99.590	$\approx$0	RobustScaler
`purchased_last_month`	10,72	Cao	$\approx$78.000	$\approx$0	RobustScaler
`discounted_price`	4,43	Cao	$\approx$45.000	$\approx$0	RobustScaler
`original_price`	4,26	Cao	$\approx$42.000	$\approx$0	RobustScaler
`discount_percentage`	2,37	Trung bình	$\approx$16.928	$\approx$0	RobustScaler
`product_rating`	$-1{,}84$	Thấp	$\approx$18.500	$\approx$0	RobustScaler / MinMax

Toàn bộ 6/6 biến bác bỏ H_0 với $p \approx 0$. Skewness của `total_reviews` đạt 24,34 – cực kỳ lệch phải, phản ánh phân phối power-law điển hình của hoạt động xem xét (review) trực tuyến: phần lớn sản phẩm có dưới 100 lượt đánh giá, một số ít viral lên tới hàng trăm nghìn. K^2 lên tới 99.590 khẳng định đây không phải lệch nhẹ mà là bất thường cực độ về hình dạng phân phối. RobustScaler dựa trên trung vị và IQR phù

hợp hơn StandardScaler vì không bị kéo lệch bởi outlier cực đoan.

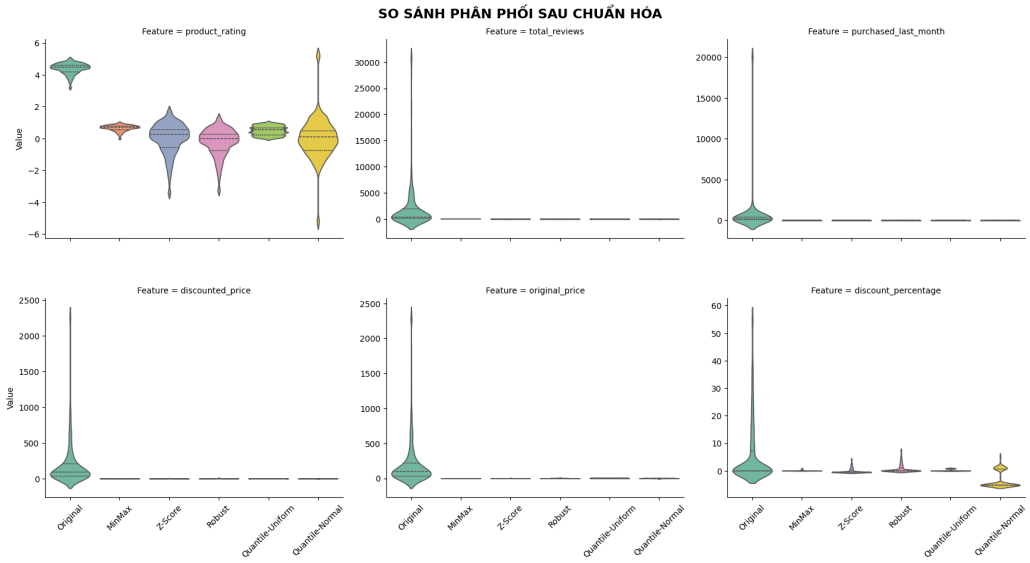

Figure 3.1: Biểu đồ Violin so sánh phân phối của 6 biến số trước (Original) và sau khi áp dụng các phương pháp chuẩn hóa khác nhau (MinMax, Z-Score, Robust, Quantile-Uniform, Quantile-Normal).

Hình 3.1 cho thấy rõ vì sao nhóm chọn RobustScaler thay vì Standard- Scaler hay MinMax. Với bốn biến đuôi dài nhất (`total_reviews`, `purchased_last_month`, `discounted_price`, `original_price`), phần "thân" của violin ở dữ liệu gốc bị ép sát về đáy do outlier cực lớn. Sau RobustScaler, khối lượng chính của dữ liệu được kéo giãn quanh trung vị và IQR, giúp mô hình nhìn rõ hơn cấu trúc của phần đông quan sát thay vì bị chi phối bởi một số sản phẩm viral. Ngược lại, `product_rating` gần như giữ nguyên hình dáng qua biến đổi, xác nhận đây là biến đã ổn định sẵn và chỉ cần đồng bộ thang đo chứ không cần "ép phân phối" mạnh.

Kết luận lựa chọn

RobustScaler cho toàn bộ 6 biến số. Ngoại lệ: `product_rating` có thể dùng MinMax nếu pipeline yêu cầu miền $[0, 1]$ (ví dụ: kết hợp với xác suất).

3.2 Phân tích tương quan – Pearson vs. Spearman

Table 3.2: So sánh hệ số tương quan Pearson và Spearman
Ngưỡng đa cộng tuyến: $|r| > 0{,}9$. Spearman dựa trên thứ hạng, bền vững hơn trước ngoại lai và quan hệ đơn điệu phi tuyến.

Cặp biến	Pearson	Spearman	Nhận định
`original_price` - `discounted_price`	0,97	0,99	Đa cộng tuyến gần hoàn hảo; loại `original_price`.
`discounted_price` - `purchased_last_month`	−0,10	−0,69	Masking effect nghiêm trọng; quan hệ nghịch đơn điệu mạnh.
`total_reviews` - `purchased_last_month`	0,30	0,47	Cùng chiều vừa phải; giữ cả hai biến.
`original_price` - `purchased_last_month`	0,09	−0,69	Masking effect rõ ràng; Pearson bị che bởi outlier.
`discount_percentage` - biến khác	≈0	≈0	Biến độc lập; giữ nguyên.

Hiện tượng *masking effect* rõ nhất ở cặp `discounted_price` – `purchased_last_month`: Pearson= −0,10 (gần như không tương quan) trong khi Spearman= −0,69 (nghịch mạnh). Pearson kém hiệu quả vì sử dụng giá trị thô – chỉ cần vài outlier sản phẩm có giá cực cao hoặc lượng mua cực lớn là kéo hệ số về gần 0. Spearman dựa trên thứ hạng nên nắm bắt được quan hệ đơn điệu phi tuyến (khi giá giảm, lượng mua tăng theo quy luật logarit/mũ chứ không tuyến tính). Đây là một ví dụ kinh điển cần dùng cả hai hệ số: Pearson cho quan hệ tuyến tính, Spearman cho quan hệ đơn điệu bất kỳ.

Kết luận lựa chọn

Loại bỏ `original_price` vì Spearman(`original_price`, `discounted_price`) = 0,99 – đa cộng tuyến gần hoàn hảo. Giữ `discounted_price` và `discount_percentage` làm biến độc lập.

3.3 Phân tích giá trị thiếu – Kiểm định Little's MCAR

Table 3.3: Phân loại cơ chế thiếu dữ liệu và đề xuất xử lý
Little's MCAR Test [1]: $\chi^2 = 6519{,}55$, $p \approx 0$ – bác bỏ MCAR. Trực quan hóa bằng `missingno`.

Thuộc tính	Tỷ lệ thiếu	Cơ chế	Đề xuất xử lý
`sustainability_tags`	92,0%	MNAR	Điền "No Tag" – NaN mang ý nghĩa thực (không có chứng nhận bền vững).
`buy_box_availability`	34,3%	MNAR	Điền "Not Available" – NaN = sản phẩm không có nút mua trực tiếp.
`delivery_date`	28,1%	MAR	k-NN Imputer theo nhóm danh mục.
`purchased_last_month`	24,6%	MAR/MNAR	k-NN Imputer hoặc MICE.
`discounted_price` / `original_price`	∼4,8%	MAR	MICE – tương quan Spearman 0,99 giữa hai biến.
`total_reviews` / `product_rating`	∼2,4%	MAR	k-NN, $k = 10$.

Little's MCAR Test [1] cho $\chi^2 = 6519{,}55$, $p \approx 0$ – bác bỏ giả thuyết MCAR. Dữ liệu thiếu không ngẫu nhiên hoàn toàn: có ba nhóm cơ chế. Nhóm MNAR điển hình là `sustainability_tags` (92% thiếu) và `buy_box_availability` (34,3% thiếu) – giá trị thiếu không phải lỗi crawl mà mang ý nghĩa nghiệp vụ rõ ràng (sản phẩm không có nhãn bền vững, sản phẩm không có nút Buy Box). Nhóm MAR bao gồm các biến giá và đánh giá – dữ liệu thiếu phụ thuộc vào các biến quan sát được khác (ví dụ: các dòng thiếu đồng thời ở `discounted_price`, `original_price` và `discount_percentage` gợi ý lỗi crawl hàng loạt khi sản phẩm bị gỡ khỏi sàn). Kết luận: listwise deletion bị loại hoàn toàn vì sẽ mất có chọn lọc các nhóm sản phẩm mới (chưa có lượt mua) hoặc sản phẩm không có chứng nhận, gây sai lệch mẫu nghiêm trọng.

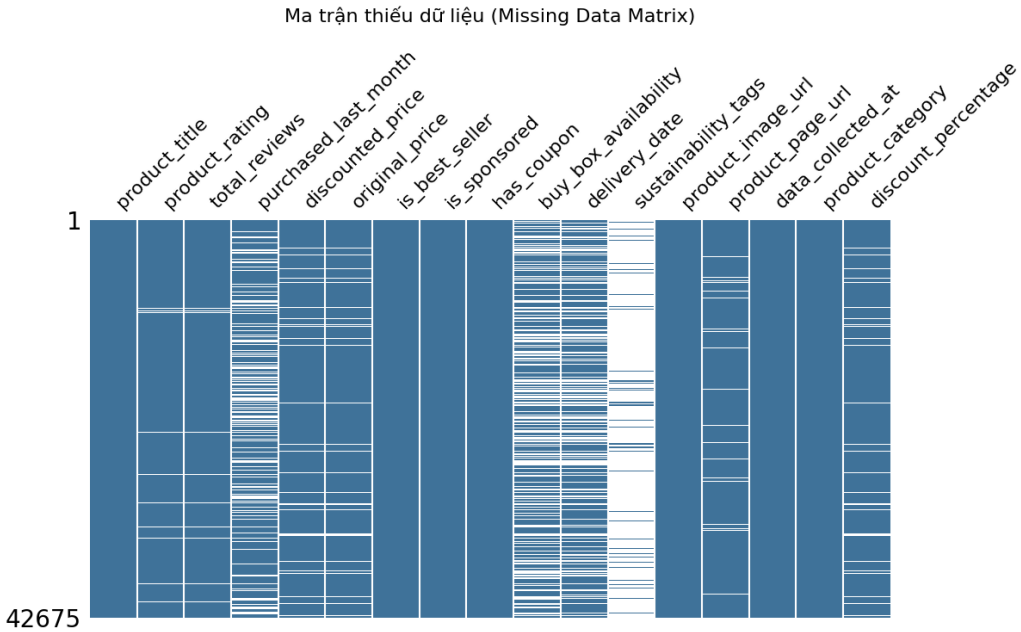

Figure 3.2: Trực quan hóa dữ liệu thiếu – tập Amazon 42.675 sản phẩm (`missingno` library).

Hình 3.2 bổ sung một điểm mà bảng số liệu khó thể hiện: dữ liệu thiếu không rơi ngẫu nhiên thành "muối tiêu" trên toàn ma trận mà tụ thành các cột và dải có cấu trúc. Cột `sustainability_tags` gần như trắng toàn phần là tín hiệu MNAR điển hình – phần lớn sản phẩm thật sự không có nhãn bền vững, chứ không phải crawler bỏ sót. Ngược lại, các cột giá và khuyến mãi xuất hiện các dải thiếu đồng thời, gợi ý cơ chế MAR theo nhóm sản phẩm hoặc trạng thái niêm yết. Đây chính là lý do báo cáo không dùng một quy tắc điền khuyết duy nhất cho mọi biến: mỗi cụm thiếu phản ánh một cơ chế sinh dữ liệu khác nhau và cần chiến lược xử lý riêng.

3.4 So sánh chiến lược điền khuyết – RMSE trên Ground Truth

Quy trình thực nghiệm nghiêm ngặt: (1) trích tập Ground Truth 30.228 hàng hoàn chỉnh 100%; (2) tạo nhân tạo 10% giá trị thiếu MCAR trên mỗi cột mục tiêu (3.022 giá trị/cột); (3) áp 5 chiến lược; (4) tính RMSE so với Ground Truth.

Table 3.4: So sánh chiến lược điền khuyết – RMSE trên Ground Truth 30.228 hàng
MICE sử dụng BayesianRidge, max_iter=10 [2]. Xếp hạng theo RMSE trung bình tất cả biến.

Chiến lược	**product_ rating**	**total_ reviews**	**purchased_ last_month**	**discounted_ price**	**RMSE TB**	**Xếp hạng**
Mode	0,3969	16.375	6.316	308,81	3.895,83	5 (kém nhất)
Median	0,3683	16.249	6.300	293,01	3.866,54	4
Mean	0,3635	15.951	6.221	278,21	3.798,36	3
k-NN ($k = 10$)	0,1855	14.790	2.582	184,62	2.938,63	1
MICE	0,3453	15.475	6.050	134,07	3.637,93	2

k-NN ($k = 10$) thắng tổng thể với RMSE trung bình 2.938,63 – thấp hơn 24,6% so với Mode (3.895,83). Điều đáng chú ý là MICE với BayesianRidge đạt RMSE tốt nhất cho `discounted_price` (134,07) nhờ khai thác quan hệ tuyến tính rất cao với `original_price` (Spearman= 0,99) – nhưng lại kém hơn k-NN đáng kể với các biến hành vi như `purchased_last_month` (6.050 so với 2.582). Lý do: MICE tối ưu hóa theo mô hình BayesianRidge (quan hệ tuyến tính), phù hợp khi biến có tương quan tuyến tính cao; còn k-NN khai thác "lân cận cục bộ" trong không gian nhiều chiều, phù hợp hơn với các biến hành vi người dùng có quan hệ phi tuyến phức tạp.

Kết luận lựa chọn

k-NN ($k = 10$) cho `product_rating`, `total_reviews`, `purchased_last_month`, `discount_percentage`. MICE (BayesianRidge) cho `discounted_price` và `original_price` (trước khi loại). Chiến lược phân tầng này cải thiện RMSE trung bình 24,6% so với Mode.

3.5 Phát hiện và xử lý ngoại lai

Table 3.5: So sánh các phương pháp phát hiện ngoại lai
KS Test Pass: số trong 6 biến liên tục có phân phối cải thiện sau khi loại ngoại lai. Jaccard Max: độ chồng lấp tập ngoại lai tối đa giữa cặp phương pháp.

Phương pháp	**Tỷ lệ phát hiện**	**KS Test Pass**	**Jaccard Max**	**Nhận định**
IQR (gộp dòng)	41,41%	0/6	0,221	False positive quá cao; IQR không phù hợp dữ liệu power-law.
Z-Score (gộp dòng)	9,14%	0/6	0,597	Bị masking effect từ outlier cực đoan làm lệch μ và σ.
Isolation Forest ($c = 0{,}05$)	$\approx$5%	2/6	0,597	Hợp lý tại elbow point của K-Distance Plot.
LOF ($k = 20$)	12,74%	3/6	$< 0{,}1$	Cân bằng tương đối an toàn.
DBSCAN ($\varepsilon = 0{,}2604$)	4,21%	3/6	0,185	Phản ánh ranh giới tự nhiên của cụm dữ liệu.

Hệ số Jaccard thấp ($\leq 0{,}6$) giữa các phương pháp cho thấy không có thuật toán đơn lẻ nào toàn diện. IQR gắn nhãn 41,41% quan sát là outlier – mức quá cao, phản ánh việc IQR không phù hợp với phân phối power-law của dữ liệu thương mại điện tử. Z-Score bị masking effect: các outlier cực đoan (total_reviews hàng trăm nghìn) kéo lệch μ và σ, làm mờ các điểm bất thường vừa. Điểm cốt lõi với dữ liệu Amazon: nhiều outlier là *business signal* hợp lý (sản phẩm viral, flash sale) chứ không phải lỗi thu thập – chiến lược xử lý phải bảo toàn những điểm này.

Kết luận lựa chọn

Dual-Treatment Pipeline: (i) Majority Voting (IF + LOF + DBSCAN) – xóa dòng chỉ khi bị đánh dấu bởi ít nhất 2/3 phương pháp ⇒ loại 1.115 dòng bất thường thực sự; (ii) Winsorization 1%–99% cho toàn bộ biến liên tục – giảm skewness mà không phá hủy business signal cốt lõi.

3.6 Chuẩn hóa dữ liệu – Kiểm định Levene

Năm phương pháp chuẩn hóa được áp dụng lên 6 biến số: **Min–Max Scaling** (co giãn về $[0, 1]$), **Z-Score** (trung bình = 0, độ lệch chuẩn = 1), **Robust Scaling** (dựa trên trung vị và IQR), **Quantile Transform – Uniform** (ánh xạ sang phân phối đều), và **Quantile Transform – Normal** (ánh xạ sang phân phối chuẩn). Để đánh giá mức thay đổi phương sai trước–sau chuẩn hóa, kiểm định Levene được thực hiện cho mỗi cặp (biến gốc, biến đã chuẩn hóa) với H_0: phương sai hai nhóm bằng nhau.

Table 3.6: Tóm tắt kiểm định Levene – phương sai trước và sau chuẩn hóa
H_0: phương sai nhóm gốc = phương sai nhóm đã chuẩn hóa. Toàn bộ 30/30 cặp bác bỏ H_0 ($p \approx 0$). Mỗi biến được kiểm định với 5 scaler; bảng trình bày khoảng W và scaler cho W thấp nhất (ít biến dạng phương sai nhất).

Biến số	$W_{\min}$	$W_{\max}$	p**-value**	**Scaler ít biến dạng nhất**
`product_rating`	92	16.372	≈ 0	Quantile-Uniform ($W = 92$)
`total_reviews`	7.478	7.486	≈ 0	Robust ($W = 7.478$)
`purchased_last_month`	2.299	2.316	≈ 0	Robust ($W = 2.299$)
`discounted_price`	10.531	10.639	≈ 0	Robust ($W = 10.531$)
`original_price`	10.403	10.509	≈ 0	Robust ($W = 10.403$)
`discount_percentage`	4.622	10.683	≈ 0	Quantile-Normal ($W = 4.622$)

Toàn bộ 30/30 cặp kiểm định bác bỏ H_0 ($p \approx 0$), xác nhận rằng mọi phương pháp chuẩn hóa đều thay đổi phương sai có ý nghĩa thống kê so với dữ liệu gốc. Kết quả này là hiển nhiên vì mục đích của chuẩn hóa chính là thay đổi thang đo; tuy nhiên, mức độ biến dạng rất khác nhau giữa các phương pháp.

Hai quan sát đáng chú ý. Thứ nhất, **RobustScaler cho Levene W thấp nhất ở 4/6 biến** – cả bốn biến đuôi dài (`total_reviews`, `purchased_last_month`, `discounted_price`, `original_price`). Điều này nhất quán với lý thuyết: Robust dựa trên trung vị và IQR nên ít "kéo giãn" phương sai hơn Z-Score (bị outlier thổi phồng σ) hay MinMax (bị outlier kéo range). Thứ hai, khoảng biến thiên $W_{\max} - W_{\min}$ ở nhóm biến đuôi dài rất hẹp (chênh <200 đơn vị) trong khi `product_rating` dao động từ 92 đến 16.372 và `discount_percentage` từ 4.622 đến 10.683 – cho thấy biến càng gần chuẩn thì việc lựa chọn scaler càng tạo ra khác biệt lớn.

Đánh giá trực quan – Biểu đồ Violin

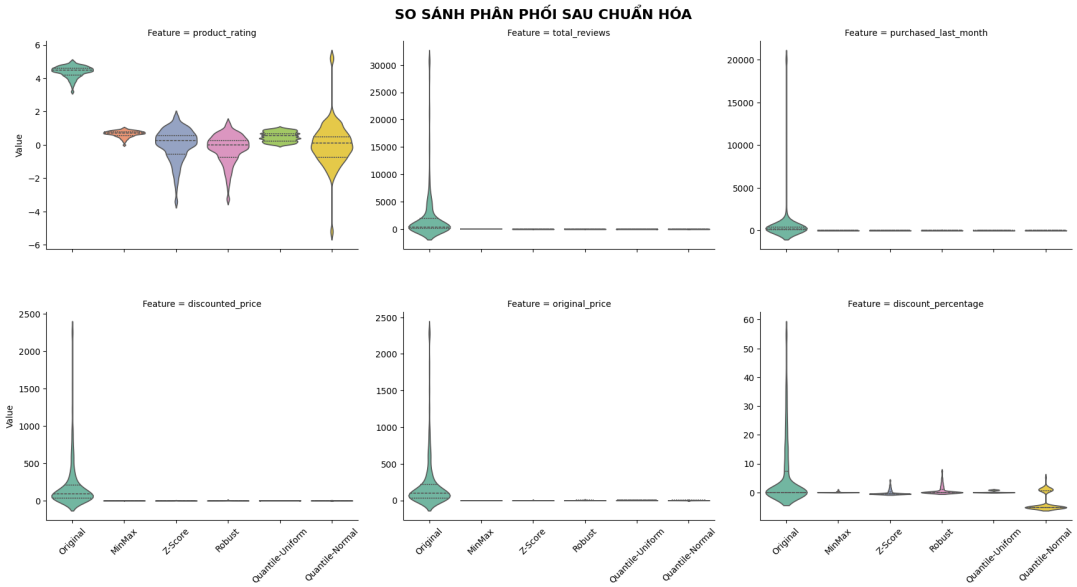

Figure 3.3: So sánh phân phối 6 biến số trước (Original) và sau 5 phương pháp chuẩn hóa. Violin plot hiển thị mật độ xác suất; đường nét đứt = trung vị và tứ phân vị.

Phân tích theo ba nhóm có các phân phối đặc biệt khác nhau:

Nhóm 1 – Đuôi dài cực đoan: `total_reviews`, `purchased_last_month`, `discounted_price`, `original_price`. Phân phối gốc lệch phải cực mạnh (skewness từ 4,26 đến 24,34) với đuôi kéo dài tới hàng chục nghìn đơn vị. Ở *tất cả* phương pháp chuẩn hóa,phần thân chính của violin bị ép sát về đáy (gần 0) do outlier cực lớn chi phối trụctung. Hiệu ứng này đặc biệt rõ ở MinMax: toàn bộ khối lượng dữ liệu nằm trong một dải mỏng dưới 0,05 trên trục $[0, 1]$, trong khi vài điểm viral kéo trục lên 1,0. RobustScaler giảm nhẹ hiện tượng này nhờ dựa trên IQR thay vì range toàn phần, nhưng không triệt tiêu hoàn toàn vì bản chất power-law của dữ liệu.

Nhóm 2 – Gần ổn định: `product_rating` (skewness = −1,84). Đây là biến duy nhất có phân phối gần chuẩn với khoảng giá trị hữu hạn [1,0; 5,0] và không có outlier cực đoan. Z-Score và RobustScaler giữ nguyên hình dáng phân phối gốc, chỉ dịch chuyển và co giãn trục – đúng mục tiêu đồng bộ thang đo. Quantile-Normal ép thành đường cong chuẩn hoàn hảo nhưng tạo ra đuôi dài bất thường ở hai biên – hệ quả của việc ánh xạ các giá trị rời rạc (1,0; 1,5; ...; 5,0) sang phân phối liên tục, kéo giãn khoảng cách giữa các mức rating thưa. MinMax nén về $[0, 1]$ nhưng bảo toàn hình dạng tổng thể.

Nhóm 3 – Lệch vừa phải, zero-inflated: `discount_percentage` (skewness = 2,37, median = 0). Hơn 50% sản phẩm không có giảm giá (giá trị = 0), tạo đỉnh tập trung tại gốc. MinMax bị kéo lệch bởi outlier nên không bảo toàn hình dạng phần phi không. Z-Score giữ nguyên hình thái gốc, nghĩa là hiện tượng lệch phải vẫn tồn tại sau chuẩn hóa. RobustScaler cải thiện tốt hơn nhờ hạn chế ảnh hưởng của các giá trị cực biên. Quantile Transform cho phân phối mượt nhất – biến đổi hoàn toàn cấu trúc zero-inflated thành phân phối liên tục – tuy nhiên điều này phá hủy thông tin "không giảm giá" vốn có ý nghĩa nghiệp vụ quan trọng.

Kết luận lựa chọn

RobustScaler là lựa chọn chính cho toàn bộ 6 biến số: (i) Levene W thấp nhất ở 4/6 biến đuôi dài; (ii) dựa trên trung vị và IQR nên ít bị chi phối bởi outlier cực đoan; (iii) không ép phân phối như Quantile Transform nên giữ được ý nghĩa nghiệp vụ của giá trị gốc. *Lưu ý:* Các mô hình tree-based (Random Forest, Gradient Boosting) không nhạy cảm với phương pháp scaling – lựa chọn này chủ yếu phục vụ Linear Regression và đồng bộ pipeline.

3.7 Mã hóa biến phân loại – Phân tích VIF

Bộ dữ liệu chứa 11 cột phân loại, chia thành hai nhóm: high-cardinality (`product_title`, `has_coupon`, `delivery_date`, `product_image_url`, `product_page_url`, `data_collected_at`) và low-cardinality (`is_best_seller`, `is_sponsored`, `buy_box_availability`, `sustainability_tags`, `product_category`). Bốn phương pháp mã hóa được đánh giá và so sánh thông qua hệ số VIF (Variance Inflation Factor) để lượng hóa mức đa cộng tuyến do mã hóa gây ra.

Table 3.7: So sánh 4 phương pháp mã hóa biến phân loại theo VIF
VIF > 10: đa cộng tuyến đáng lo ngại. Số biến VIF > 10 chỉ tính các biến do mã hóa sinh ra hoặc bị ảnh hưởng bởi mã hóa.

Phương pháp	**Số features**	**Max VIF**	**Mean VIF**	**VIF > 10**	**Vấn đề chính**
One-Hot Encoding	46	30,03	3,429	3	Dummy variable trap ở `sustainability_tags` (VIF = 19,96); bùng nổ chiều.
Target Encoding	16	470,10	63,555	4	Data leakage nghiêm trọng từ cột định danh (URL, title → VIF ≈ 470).
Binary Encoding	74	32,08	2,955	4	Sinh 74 features (nhiều hơn OHE); MSB tương quan cao; mất ý nghĩa ngữ nghĩa.
Frequency Encoding	16	29,79	4,977	2	Chỉ 2 biến VIF > 10 là `discounted_price` và `original_price` – đa cộng tuyến nội tại, không do mã hóa gây ra.

Frequency Encoding là lựa chọn tối ưu: giữ nguyên 16 đặc trưng, mean VIF thấp (4,977), và quan trọng nhất – không tạo ra đa cộng tuyến mới nào. Hai biến duy nhất có VIF > 10 (`discounted_price` và `original_price`) là vấn đề nội tại của dữ liệu số (Spearman = 0,99), không liên quan đến phương pháp mã hóa.

Target Encoding bộc lộ rủi ro nghiêm trọng nhất: các cột định danh như `product_image_url` và `product_title` có cardinality gần bằng số dòng dữ liệu, khiến mô hình học ánh xạ 1–1 từ định danh sang target – đẩy VIF lên ≈ 470 và tạo data leakage khó phát hiện nếu không kiểm tra VIF. Binary Encoding tuy có mean VIF thấp nhất (2,955) nhưng sinh ra 74 features – nhiều hơn cả One-Hot (46) – do nhiều biến high-cardinality đóng góp nhiều cột bit, đồng thời các cột bit mất hoàn toàn ý nghĩa ngữ nghĩa, bất lợi cho mô hình tuyến tính cần diễn giải hệ số.

Kết luận lựa chọn

Frequency Encoding cho toàn bộ biến phân loại. Trước khi vào bước Feature Selection, thực hiện hai hành động bắt buộc:

1. **Loại bỏ `original_price`** – đa cộng tuyến nội tại với `discounted_price` (Spearman = 0,99); thông tin giá gốc đã được biểu diễn gián tiếp qua `discount_percentage`.
2. **Loại bỏ các cột định danh** (`product_page_url`, `product_image_url`, `product_title`, `data_collected_at`) – không mang thông tin dự đoán cho `purchased_last_month`; giữ lại chỉ gây nhiễu và tăng VIF.

3.8 Lựa chọn đặc trưng và giảm chiều dữ liệu

Quy trình lựa chọn đặc trưng được thiết kế theo ba tầng: Tầng 1 (Filter) dùng kiểm định thống kê, Tầng 2 (Wrapper/Embedded) dùng mô hình, Tầng 3 (Dimensionality Reduction) khảo sát khả năng nén không gian. Toàn bộ R^2 đều đo bằng Linear Regression 5-fold CV.

Table 3.8: Tổng hợp kết quả lựa chọn đặc trưng – 3 tầng
Mọi phương pháp hội tụ về $R^2 \approx 0{,}2348$ – ceiling của Linear Regression trên 10 features hiện tại.

Tầng	Phương pháp	R^2	k	Kết quả chính
1	ANOVA	0,0974	4	Chỉ đo linear; `total_reviews` $F = 3.239$.
1	Chi-square	0,1553	6	Phụ thuộc binning; `buy_box` $\chi^2 = 292$.
1	Mutual Information	**0,2348**	10	Phi tuyến; `discounted_price` lên vị trí 2.
2	RF / GB Importance	∼0,2348	10	`total_reviews` chiếm 84–85% importance.
2	RFE-CV	0,2348	8	Loại 2 features; elbow thực tế $\approx k = 6$.
3	PCA	0,2348	10	9 PCs cho 90% variance – không giảm chiều được.
3	t-SNE	N/A	N/A	Không tạo cluster rõ theo target.

Bảng 3.8 cho thấy mọi phương pháp đều hội tụ về $R^2 \approx 0{,}2348$. Đây là ceiling

của thông tin trong 10 features hiện tại khi dự đoán bằng mô hình tuyến tính, không phải do thiếu features hay do feature selection chưa tốt. Random Forest trên cùng tập features đạt $R^2 \approx 0{,}96$ – khoảng cách 4× khẳng định dữ liệu có quan hệ phi tuyến rất mạnh. Hiện tượng feature dominance của `total_reviews` (84–85% importance ở cả RF và GB) cần lưu ý: có khả năng tồn tại reverse causality (bán nhiều → nhiều review). PCA cần 9/10 PCs để đạt 90% variance, xác nhận không có dư thừa chiều thực sự.

Kết luận lựa chọn

Giữ 10 features. Ceiling $R^2 = 0{,}2348$ là giới hạn của mô hình tuyến tính, không phải của dữ liệu. Hướng cải thiện: (i) mô hình phi tuyến; (ii) feature engineering (biến tỉ lệ, tương tác).

3.9 Phát hiện và xử lý mất cân bằng lớp

Biến mục tiêu liên tục `purchased_last_month` được chuyển thành nhãn nhị phân `is_popular`: giá trị 1 nếu lượng mua ≥ P90 (≥ 1.000 đơn vị/tháng), ngược lại 0. Phân bố lớp: Not Popular 37.134 mẫu (89,4%), Popular 4.426 mẫu (10,6%) – tỉ lệ mất cân bằng ≈ 1:8. Dữ liệu được chia train/test theo tỉ lệ 80/20 với stratified sampling **trước khi** áp dụng resampling để tránh rò rỉ dữ liệu. Ba chiến lược resampling được áp dụng **chỉ trên tập train**:

- **SMOTE** – tạo mẫu tổng hợp bằng nội suy k-NN: lớp 1 từ 3.541 → 29.707 (×8,4); tổng train = 59.414.
- **ADASYN** – mở rộng SMOTE, tập trung sinh mẫu ở vùng khó phân loại: lớp 1 → 29.694; tổng train = 59.401.
- **Random Under-sampling** – giảm ngẫu nhiên lớp đa số: lớp 0 từ 29.707 → 3.541 (−88%); tổng train = 7.082.

Hai mô hình – Random Forest và Gradient Boosting – được huấn luyện trên mỗi tập train đã resampled và đánh giá trên tập test gốc (không resampled) bằng Precision, Recall, F1-macro và AUC-ROC.

Table 3.9: Kết quả phân loại `is_popular` – 4 chiến lược × 2 mô hình
Đánh giá trên tập test gốc (8.312 mẫu, giữ nguyên tỉ lệ 89,4/10,6%). Giá trị tốt nhất mỗi cột được in đậm.

Strategy	Model	Precision	Recall	F1-macro	AUC-ROC	Train size
No Resampling	Random Forest	**0,9287**	0,7503	**0,9059**	0,9879	33.248
No Resampling	Gradient Boosting	0,8898	0,7571	0,8991	0,9779	33.248
SMOTE	Random Forest	0,7222	0,9017	0,8875	**0,9881**	59.414
SMOTE	Gradient Boosting	0,7696	0,8644	0,8953	0,9817	59.414
ADASYN	Random Forest	0,5894	**0,9537**	0,8423	0,9859	59.401
ADASYN	Gradient Boosting	0,6694	0,9107	0,8694	0,9814	59.401
Under-sampling	Random Forest	0,6634	0,9311	0,8709	0,9874	7.082
Under-sampling	Gradient Boosting	0,6516	0,9130	0,8627	0,9813	7.082

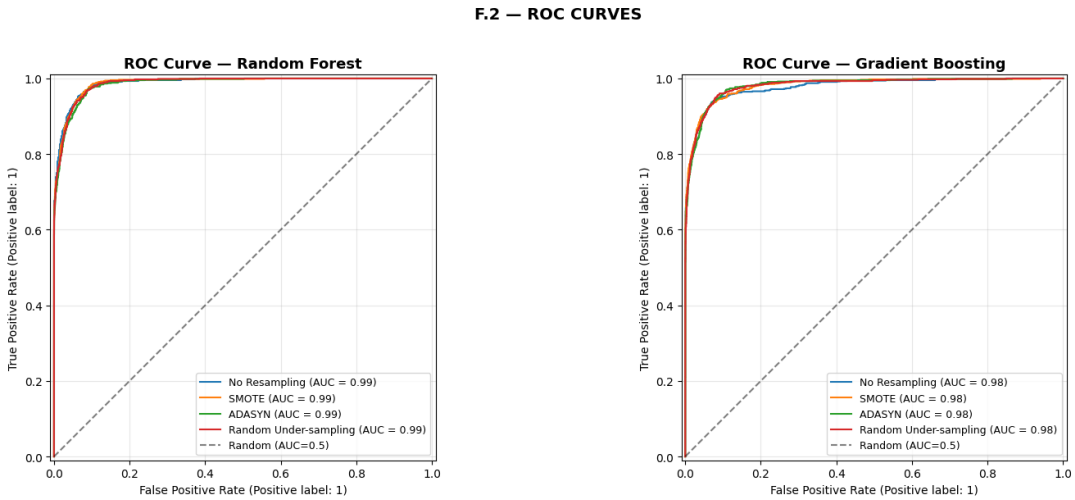

Figure 3.4: ROC Curves – Random Forest (trái) và Gradient Boosting (phải). Toàn bộ chiến lược đều đạt AUC $\geq$ 0,98; các đường cong gần như chồng lấp hoàn toàn.

Ba quan sát chính từ Bảng 3.9 và Hình 3.4. Thứ nhất, resampling tạo ra sự đánh đổi có hệ thống giữa Precision và Recall: No Resampling cho Precision cao nhất (0,9287) nhưng Recall thấp nhất (0,7503); ADASYN đẩy Recall lên 0,9537 nhưng kéo Precision xuống 0,5894 – nghĩa là gần một nửa dự đoán "Popular" là sai. SMOTE cân bằng tốt

nhất giữa hai chỉ số (Precision = 0,72, Recall = 0,90). Thứ hai, AUC-ROC đồng thuận quanh 0,98–0,99 ở tất cả 8 cấu hình, các đường ROC gần như chồng lấp hoàn toàn (Hình 3.4), chứng tỏ resampling không cải thiện khả năng phân biệt (discriminative power) mà chỉ dịch chuyển ngưỡng quyết định (decision boundary). Thứ ba, Random Forest nhất quán vượt trội Gradient Boosting ở mọi chiến lược, đặc biệt ở F1-macro (chênh 0,5–0,8%).

Kết luận lựa chọn

Khuyến nghị theo mục tiêu nghiệp vụ:

- Ưu tiên F1-macro tổng thể: **No Resampling + Random Forest** (F1 = 0,9059).
- Ưu tiên phát hiện sản phẩm Popular: **SMOTE + Random Forest** (Recall = 0,90, Precision = 0,72).
- Với tỉ lệ 1:8 và 4.426 mẫu thiểu số, resampling mang lại lợi ích hạn chế – kỹ thuật này chỉ thực sự cần thiết khi imbalance > 1:20 hoặc minority < 500 mẫu.

Quy tắc bắt buộc: áp dụng resampling **chỉ sau** train/test split để tránh data leakage – mẫu tổng hợp có thể chứa thông tin từ test neighbors, thổi phồng metrics đánh giá.

Kết luận Phần 2 – Pipeline tối ưu cho dữ liệu bảng

- **Phân phối:** 6/6 biến không chuẩn ($p \approx 0$) ⇒ RobustScaler.
- **Tương quan:** Loại `original_price` (Spearman = 0,99 với `discounted_price`).
- **Giá trị thiếu:** Không MCAR ($\chi^2 = 6519$) ⇒ k-NN cho biến hành vi, MICE cho biến giá.
- **Ngoại lai:** Majority Voting (IF+LOF+DBSCAN) + Winsorization ⇒ loại 1.115 dòng, skewness 12,32 → 6,04.
- **Mã hóa:** Frequency Encoding (16 features, mean VIF = 4,977).
- **Đặc trưng:** 3 tầng hội tụ $R^2 \approx 0{,}23$ (LR) vs. 0,96 (RF) ⇒ phi tuyến mạnh.
- **Mất cân bằng:** No Resampling + RF cho F1-macro cao nhất (0,9059); SMOTE + RF cân bằng tốt nhất (Prec = 0,72, Rec = 0,90). AUC-ROC ≈ 0,99 ở mọi chiến lược – resampling chỉ dịch decision boundary.

4. Phân tích và tiền xử lý dữ liệu văn bản

Tập IMDB Dataset of 50K Movie Reviews [9] gồm 50.000 bài đánh giá phim cân bằng tuyệt đối (25.000 Positive / 25.000 Negative). Đây là điều kiện lý tưởng cho phân loại: accuracy là metric đáng tin cậy, không cần resampling.

4.1 Phân tích phân phối độ dài văn bản

Table 4.1: So sánh đặc trưng độ dài giữa hai lớp cảm xúc

Kiểm định Mann–Whitney U (H_0: hai lớp có phân phối độ dài như nhau). Tập IMDB 50.000 bài.

Đặc trưng	**Positive**	**Negative**	**Mann–Whitney U**	**Kết luận**
Số từ – Trung vị	172 từ	174 từ	$p = 0{,}0287$	Có ý nghĩa thống kê nhưng không có giá trị thực tiễn (chênh lệch 2 từ).
Số từ – Trung bình	≈230 từ	≈232 từ	—	Phân phối lệch phải mạnh ($mean \gg median$).
Số ký tự – Trung vị	968	973	$p = 0{,}173$	Không phân biệt được lớp.
Giá trị cực đại	2.470 từ	1.522 từ	—	Positive có đuôi phân phối dài hơn.

4.1.1 Phân phối số từ (Word Count)

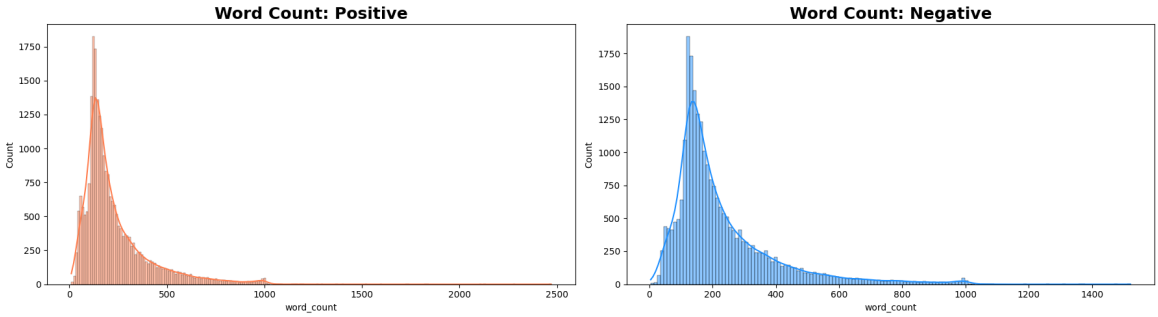

(a) Histogram số từ theo hai nhãn Positive và Negative.

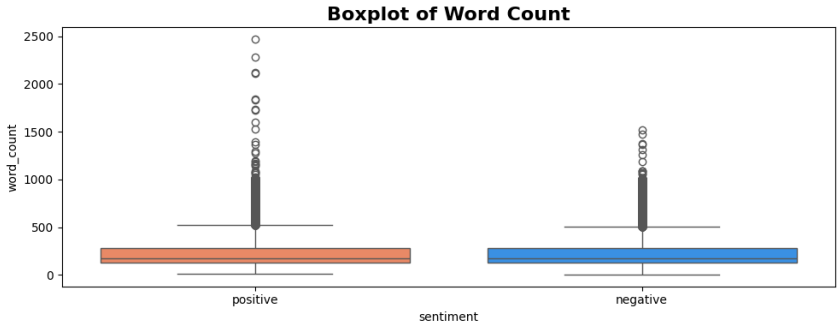

(b) Boxplot số từ theo nhãn lớp.

Figure 4.1: Phân phối số từ theo nhãn lớp. Histogram cho thấy cả hai lớp đều lệch phải mạnh; boxplot xác nhận vùng lõi IQR gần như chồng khít.

Phân phối số từ của cả hai lớp đều có dạng **lệch phải rất mạnh** (right-skewed): trung bình (≈230 từ) lớn hơn hẳn trung vị (≈173 từ), phản ánh thực tế phần lớn người dùng viết đánh giá ngắn gọn (100–200 từ), trong khi một số ít viết "tâm thư" cực dài. Boxplot cho thấy vùng lõi IQR của hai lớp gần như chồng khít (Positive: 159, Negative: 150), nghĩa là **độ dài từ không mang giá trị phân biệt nhãn**. Kết quả kiểm định Mann–Whitney U đạt $p = 0{,}0287$ – tuy có ý nghĩa thống kê nhưng hoàn toàn **không có giá trị thực tiễn**: với $N = 50.000$, chênh lệch trung vị chỉ 2 từ vẫn đủ để bác bỏ H_0 – đây là minh họa điển hình của sự phân biệt giữa *statistical significance* và *practical significance*.

Sự khác biệt duy nhất có ý nghĩa nằm ở phần đuôi phân phối: lớp Positive có max 2.470 từ, vượt xa mức 1.522 của Negative. Giả thuyết tâm lý: người hài lòng có xu hướng viết bài phân tích dài dòng, trong khi người thất vọng thường đi thẳng vào vấn đề. Đáng chú ý, biểu đồ histogram cho thấy một **đỉnh bất thường ở ≈1.000 từ** – rất có thể do IMDb API truncation khi thu thập dữ liệu; cần sanity check trước khi dùng Transformer vì bước cắt chuỗi có thể mất phần câu quyết định cảm xúc ở cuối bài.

4.1.2 Phân phối số ký tự (Character Length)

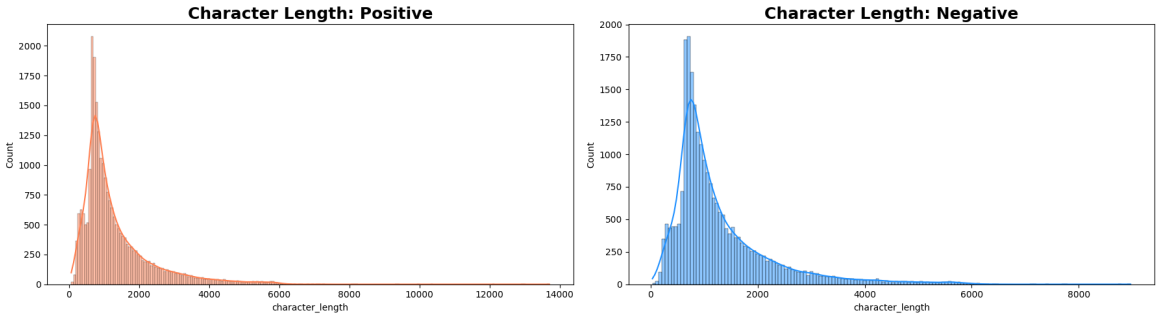

(a) Histogram số ký tự theo hai nhãn Positive và Negative.

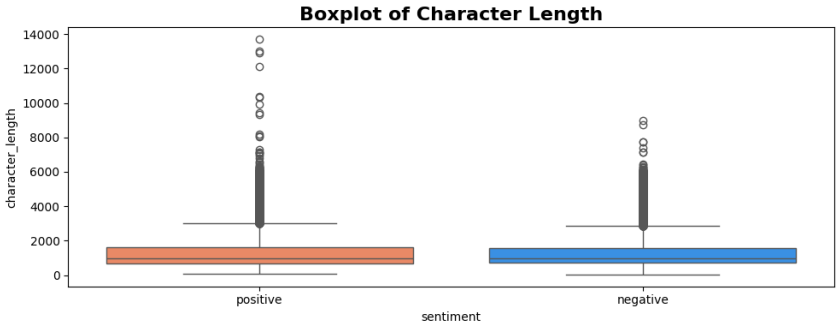

(b) Boxplot số ký tự theo nhãn lớp.

Figure 4.2: Phân phối số ký tự theo nhãn lớp. Histogram cho thấy hai lớp cùng lệch phải mạnh; boxplot xác nhận trung vị gần như tương đương và chênh lệch rất nhỏ.

Phân phối số ký tự phản ánh cùng hình thái lệch phải như số từ, với trung bình (≈1.310 ký tự) bị kéo lên cao hơn nhiều so với trung vị (≈970 ký tự). Kiểm tra sanity: tỷ lệ 1.310/231 ≈ 5,6 ký tự/từ (bao gồm dấu câu và khoảng trắng) khớp chính xác đặc trưng tự nhiên của tiếng Anh – tập không bị lỗi encoding.

Điểm khác biệt quan trọng so với Word Count: kiểm định Mann–Whitney U cho $p = 0{,}173$ ($\geq 0{,}05$), tức là **không có đủ bằng chứng để bác bỏ** H_0. Trong khi p-value của Word Count đạt 0,0287 chủ yếu do ảnh hưởng của outliers cực đại (Positive max = 13.704 ký tự so với Negative max = 8.969 ký tự), thì số ký tự hoàn toàn không phân biệt được nhãn ở cấp độ dân số. Kết luận: **tuyệt đối không nên** đưa biến này vào mô hình phân loại vì nó chỉ gây nhiễu mà không mang lại Information Gain.

Kết luận lựa chọn

`max_length`= 300 word tokens cho BoW/TF-IDF; 300−400 model tokens cho BERT/RoBERTa. Loại bỏ các dòng có `word_count`< 10 và `char_length`< 50.

4.2 Độ phong phú từ vựng – TTR và Word Cloud

Table 4.2: So sánh độ phong phú từ vựng (TTR) giữa hai lớp

TTR = số types duy nhất / tổng tokens. Tính sau lowercase và loại dấu câu.

Chỉ số	Positive	Negative	Nhận định
Tổng tokens	2.773.836	2.669.821	Cân bằng tốt – độ lệch chỉ 3,9%.
Tổng types (unique)	74.057	71.067	Positive dùng từ vựng phong phú hơn nhẹ.
TTR	2,67%	2,66%	Hai lớp đồng nhất về đa dạng từ vựng. TTR thấp do tập lớn (định luật Heaps).
Từ cảm xúc đặc trưng	*great, love, best*	*bad, worst, awful, waste*	Positive biểu đạt trực diện; Negative đánh giá cực đoan.

(a) Word Cloud lớp Positive. **(b)** Word Cloud lớp Negative.

Figure 4.3: Word Cloud theo nhãn lớp sau khi loại domain stopwords. Lớp Positive nổi bật các từ *great, love, best*; lớp Negative nhấn mạnh *bad, worst, awful, waste*.

TTR của cả hai lớp hội tụ ở mức ≈2,67% – thấp là hệ quả tất yếu của tập dữ liệu lớn (định luật Heaps): khi corpus tăng, tỷ lệ từ mới giảm dần vì các hư từ và từ khóa cốt lõi liên tục lặp lại. Sự đồng nhất TTR giữa hai lớp cho thấy **độ đa dạng từ vựng không phải đặc trưng phân biệt** – mô hình cần tập trung vào *nội dung* thay vì *số lượng* từ vựng.

Phân tích top-50 tần suất tiết lộ hai nghịch lý quan trọng. Thứ nhất, từ *good* xuất hiện **14.728 lần trong lớp Negative** – bằng chứng trực tiếp rằng unigram riêng

lẻ dễ đọc sai nghĩa khi bỏ qua ngữ cảnh phủ định (*it was not good*, *good grief*). Thứ hai, từ *like* đứng đầu cả hai lớp (Positive: 17.714 lần, Negative: 22.458 lần) – là "từ đệm" xuất hiện phổ biến bất kể cảm xúc và hoàn toàn vô nghĩa với mô hình unigram. Ngược lại, lớp Negative để lộ "dấu ấn chẩn đoán" rõ rệt: các từ kỹ thuật *plot, acting, script* chiếm tần suất cao – khi ghét một bộ phim, người xem đóng vai nhà phê bình và chỉ đích danh nguyên nhân thất bại. **N-gram là yêu cầu gần như bắt buộc** để mô hình giải mã đúng sắc thái phủ định.

4.3 Phân tích định luật Zipf

Table 4.3: Các chỉ số chính trong phân tích định luật Zipf

Tập IMDB 50.000 bài sau lowercase và loại dấu câu.

Chỉ số	**Giá trị**	**Ý nghĩa**
Hệ số R^2	0,9804 (98,04%)	Tuân thủ nghiêm ngặt Zipf ($> 0{,}95$) – xác nhận dữ liệu người thật, không phải bot/spam.
Hệ số α	1,09	Cao hơn chuẩn 1,0 – phản ánh tính chuyên biệt miền điện ảnh (nhiều thuật ngữ kỹ thuật, tên riêng).
Kích thước từ vựng	99.230 từ	Không gian đặc trưng rất lớn – cần cắt tỉa.
Hapax Legomena	37.295 từ (37%)	Lỗi chính tả, tên riêng, biến thể hiếm – cần `min_df`≥ 5.
Từ xuất hiện < 3 lần	49.150 từ (50%)	Xác nhận cần `min_df`$= 5-10$.

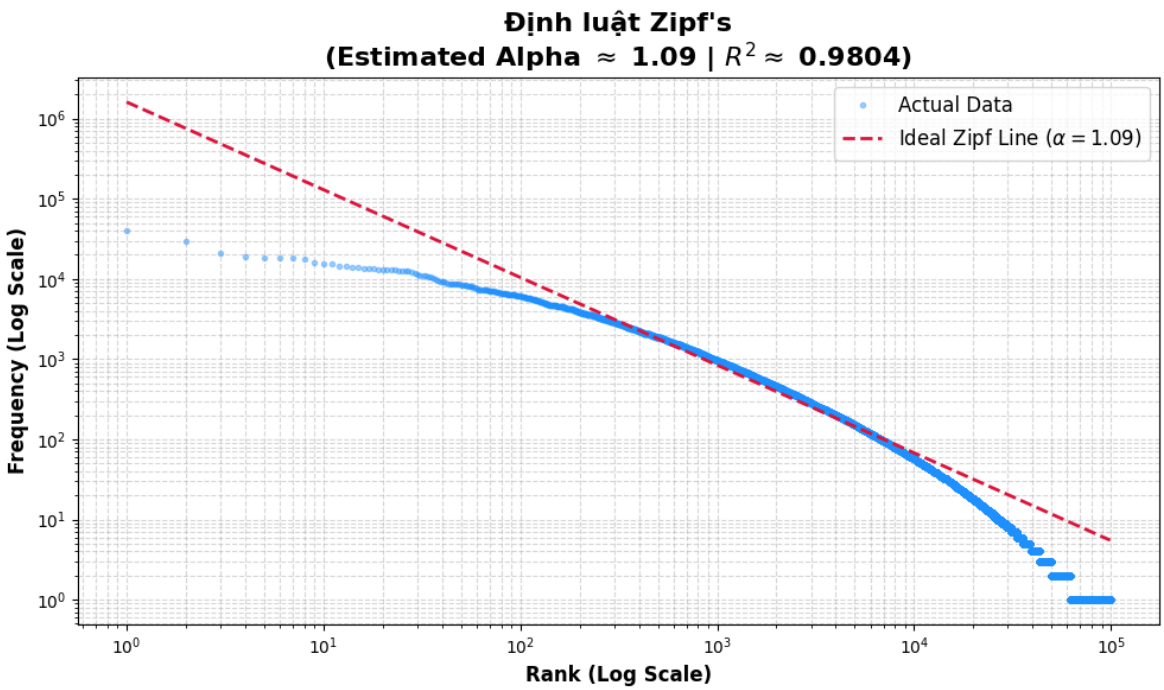

Figure 4.4: Phân tích định luật Zipf – tập IMDB 50.000 bài ($\alpha = 1{,}09$, $R^2 = 0{,}9804$, từ vựng 99.230 types).

Biểu đồ log-log cho thấy ba vùng đặc trưng. **Vùng đầu (head)**: các điểm thực nghiệm nằm thấp hơn đường Zipf lý tưởng vì stopwords đã bị lọc bỏ một phần, khiến top-1 không phải *the/a/is* mà là *movie/film* – tần suất không đạt đỉnh lý thuyết. **Vùng thân (body)**: các điểm bám sát đường đứt nét gần như hoàn hảo – minh chứng ngôn ngữ phát triển tự nhiên, không phải bot/spam tạo ra. **Vùng đuôi (tail)**: xuất hiện hiện tượng "bậc thang" do tần suất là số nguyên; hàng chục nghìn từ cùng chia sẻ tần suất 1, 2, 3 tạo ra các dải nằm ngang đứt đoạn.

Hệ số $\alpha = 1{,}09$ (cao hơn chuẩn ngôn ngữ tự nhiên $\alpha = 1{,}0$) phản ánh tính chuyên biệt miền điện ảnh: người dùng tập trung lặp lại một nhóm từ hẹp về phim ảnh, khiến các từ khác tụt hạng nhanh hơn bình thường. $R^2 = 0{,}9804$ xác nhận tập dữ liệu là **ngôn ngữ người thật**, đồng thời cung cấp cơ sở khoa học cho hai quyết định tiền xử lý: cắt đuôi bằng `min_df`= 5 (loại 49.150 từ hiếm) và cắt đỉnh bằng `max_df`= 0,95 (loại domain stopwords như *movie, film* xuất hiện ở hơn 95% văn bản).

4.4 So sánh kỹ thuật tiền xử lý văn bản

4.4.1 Pipeline chuẩn hóa – Tác động định lượng từng bước

Table 4.4: Tác động của từng bước chuẩn hóa lên `vocab_change_ratio` và phân phối độ dài *`vocab_change_ratio = (prev_vocab_size − curr_vocab_size) / prev_vocab_size`.*

Bước xử lý	**vocab_change _ratio**	**Δ word_len**	**Δ char_len**	**Mức độ**
1. Lowercase	0,4418	0	0	**Lớn**
2. Remove HTML	0,0886	−2,29	Giảm nhẹ	Trung bình
3. Remove URL	0,0005	0	0	Rất thấp
4. Remove Mention	0	0	0	Không đáng kể
5. Remove Hashtag	0,0004	0	0	Rất thấp
6. Remove Special Characters	0,7519	−1,00	Giảm mạnh	**Lớn nhất**
7. Remove Numbers	0,0118	−1,06	Giảm nhẹ	Thấp
8. Normalize Whitespace	0	0	Giảm nhẹ	Không đáng kể

Hai bước tác động lớn nhất là **lowercase** (`vocab_change_ratio` = 0,4418) và **remove_special_characters** (0,7519). Lowercase gộp hàng chục nghìn biến thể viết hoa (*The*, *THE*, *the*) về cùng một type mà không mất thông tin – đây là bước có **tỷ lệ lợi ích/rủi ro tốt nhất** trong toàn pipeline. Remove special characters có tác động lớn nhất đến cả `vocab_change_ratio` và `char_len_mean`: loại bỏ toàn bộ dấu câu, ký hiệu, và các chuỗi HTML như `<br />` giúp làm sạch sâu không gian đặc trưng, đặc biệt hiệu quả với IMDB vốn chứa nhiều markup tag thô do quá trình web scraping.

Đáng chú ý: **remove_url** và **remove_mention** có tác động gần như bằng 0, phản ánh bản chất của IMDB – đây là bài đánh giá phim viết trước năm 2011, không phải tweet hay comment mạng xã hội hiện đại. Tương tự, remove_hashtag cũng vô hiệu với corpus này. Trong thực tiễn xây dựng pipeline, **nên giữ lại các bước này** cho tính tổng quát khi áp dụng sang domain khác, nhưng không cần kỳ vọng tác động lớn với IMDB.

4.4.2 So sánh chiến lược Tokenization

Table 4.5: So sánh các chiến lược tokenization

OOV Ratio: tỷ lệ token ngoài từ vựng trên tập test (80/20 split, stratified). Subword BPE: HuggingFace `tokenizers`.

Chiến lược	**Vocab Size**	**OOV Ratio**	**Avg Seq Length**	**Phù hợp cho**
Character-level	158	≈0	≈1.291 tok	Không thực tế — chuỗi quá dài, thiếu ngữ nghĩa.
Word-level (NLTK)	134 558	0,0073	≈265 tok	BoW, TF-IDF.
Word-level (spaCy)	110 749	0,0055	≈269 tok	BoW, TF-IDF — ổn định hơn NLTK.
Sentence-level	470 742	0,9550	≈12 tok	Không phù hợp — OOV = 95,5%.
Subword BPE (HF)	15 883	0,000008	≈288 tok	BERT, RoBERTa.

Kết quả thực nghiệm phân tách rõ ràng thành ba nhóm. **Thất bại hoàn toàn**: Sentence-level với OOV = 95,5% – câu trong tập test gần như không trùng với câu trong tập train, vocab size 470.742 phần lớn là unique sentences vô dụng. Character-level không có OOV nhưng chuỗi 1.291 tokens/tài liệu vượt quá giới hạn thực tế của mọi kiến trúc hiện tại. **Phù hợp cho classical ML**: Word-level (NLTK/spaCy) cho OOV rất thấp ($< 1\%$), độ dài chuỗi ≈267 tokens tương thích với BoW và TF-IDF. spaCy ổn định hơn NLTK do pipeline tokenizer chặt chẽ hơn (vocab nhỏ hơn 18% với OOV thấp hơn). **Tối ưu cho Transformer**: Subword BPE đạt cân bằng lý tưởng – vocab 15.883 có giới hạn, OOV ≈ 0, và độ dài 288 tokens tương thích với giới hạn 512 của BERT [7]. Bản chất của BPE: các từ hiếm hoặc sai chính tả được tách thành các subword phổ biến hơn, giải quyết trực tiếp vấn đề 37% Hapax Legomena đã phát hiện ở phân tích Zipf.

4.4.3 Loại bỏ stop words – Phân tích định lượng MI và Naive Bayes

Table 4.6: Tác động của loại bỏ stop words lên vocab, Mutual Information và hiệu năng Naive Bayes
MI: Mutual Information trung bình giữa từ và nhãn. Naive Bayes (Multinomial, min_df= 2).

Cài đặt	Vocab Size	Mean MI	NB Accuracy	NB F1-Macro	Nhận định
Trước loại bỏ	54.777	0,000088	0,8441	0,8440	Baseline
Sau loại bỏ	54.625	0,000083	**0,8625**	**0,8625**	Tốt hơn +1,84%
Δ	-152	$-0{,}000004$	$+0{,}0184$	$+0{,}0185$	—

Kết quả phản trực giác: vocab giảm chỉ 152 types (0,28%) nhưng Naive Bayes accuracy tăng +1,84%. Cơ chế: stop words như *the*, *a*, *is* chiếm phần lớn tổng số tokens nhưng đóng góp rất ít Information Gain – loại bỏ chúng giúp TF-IDF gán trọng số cao hơn cho các từ có giá trị phân biệt thực sự (*great*, *awful*, *waste*). Mean MI giảm nhẹ ($-0{,}000004$) vì phép tính MI trung bình được chia cho số lượng từ sau khi loại bỏ stop words – các từ MI cao nhất vẫn được giữ nguyên, chỉ là mẫu số thay đổi.

Lưu ý quan trọng: **tuyệt đối không được đưa các từ phủ định vào danh sách stop words**. Từ *not*, *no*, *never*, *without* và các từ nhấn mạnh *even*, *really*, *just* đóng vai trò sống còn trong việc đảo nghĩa (cần giữ lại trong danh sách stop words tùy chỉnh). Phân tích EDA đã chỉ ra *good* xuất hiện 14.728 lần trong Negative – nếu mô hình không nhận ra "*not good*", accuracy sẽ giảm đáng kể.

4.4.4 Stemming và Lemmatization – Collision Rate và 5-fold CV

Table 4.7: So sánh stemming và lemmatization – Logistic Regression, 5-fold CV
Collision Rate: tỷ lệ các từ khác nhau bị map về cùng dạng gốc. TF-IDF Unigram.

Phương pháp	**Collision Rate**	**Accuracy (5-fold CV)**	**Thời gian (giây)**	**RAM (MB)**
Original Text	—	**0,8901**	34,46	178,22
Porter Stemmer	8,57%	0,8866	27,88	175,48
Snowball Stemmer	13,75%	0,8870	19,45	174,85
WordNet Lemmatizer	2,32%	**0,8902**	19,69	175,54

Collision rate phản ánh mức độ "over-stemming": Porter gom 8,57% cặp từ khác nhau về cùng dạng (điển hình: *universe* và *university* đều thành *univers*), Snowball tệ hơn với 13,75%. Mất mát ngữ nghĩa này giải thích tại sao accuracy giảm nhẹ so với Original Text – mô hình mất khả năng phân biệt những cặp từ bị gộp nhầm.

WordNet Lemmatizer dùng từ điển và POS tag để map về dạng gốc ngữ nghĩa, đạt collision rate chỉ 2,32% và duy trì accuracy 0,8902 – **gần như bằng Original Text** (0,8901) nhưng tiết kiệm 43% thời gian (19,69s so với 34,46s) và giảm nhẹ RAM. Đây là bằng chứng quan trọng: IMDB đã khá sạch về mặt hình thái học nên lợi ích chính của lemmatization không phải cải thiện accuracy mà là **giảm không gian đặc trưng** (vocab nhỏ hơn, ít chiều hơn) và **tăng tốc độ huấn luyện**, đặc biệt có giá trị khi scale lên tập dữ liệu lớn hơn hoặc kết hợp với grid search.

4.5 Vector hóa văn bản – TF-IDF vs. SBERT

4.5.1 So sánh tổng quan các chiến lược vector hóa

Table 4.8: So sánh các chiến lược vector hóa cho bài toán phân loại cảm xúc
Classifier: LinearSVC (C=1). Silhouette Score: K-Means (k = 2). SBERT: `all-MiniLM-L6-v2` *[6]. TF-IDF [5].*

Phương pháp	**Acc (LinearSVC)**	**F1-Macro**	**AUC**	**Silhouette**	**Nhận định**
TF-IDF Unigram	**0,8954**	**0,8954**	0,8764	0,1698	Tốt nhất với classifier tuyến tính.
TF-IDF Bigram	≈0,893	≈0,893	—	—	Nắm bắt tốt ngữ cảnh phủ định.
BoW	≈0,880	≈0,880	—	—	Baseline đơn giản.
Word2Vec (trained)	≈0,845	≈0,845	—	—	Cần mô hình phi tuyến.
SBERT	0,8234	0,8234	0,8086	0,1303	Cần MLP/SVM-RBF để phát huy.

4.5.2 Phân tích khả năng phân cụm – Silhouette Score theo k

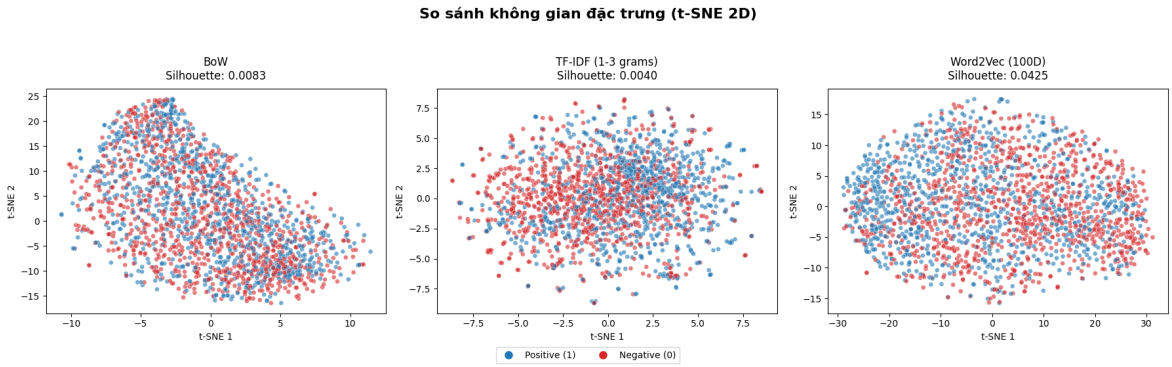

Figure 4.5: Trực quan hóa t-SNE 2D (2.000 mẫu) của ba không gian đặc trưng: BoW, TF-IDF Unigram, và Word2Vec (Mean Pooling). Cả ba đều không tách được hai lớp cảm xúc bằng ranh giới hình học đơn giản.

Silhouette Score trên toàn bộ các giá trị $k \in \{2, 5, 7\}$ dao động trong khoảng 0,12–0,17 – thấp theo tiêu chuẩn tabular data nhưng **hoàn toàn điển hình cho NLP**: văn bản mang tính đa nghĩa, đa chủ đề, dẫn đến chồng lấn ranh giới tự nhiên. Ba biểu đồ t-SNE đều hiển thị một "đám mây" nơi Positive và Negative đan xen đặc kín – khách hàng dùng chung rất nhiều từ vựng cho cả khen lẫn chê, khiến không gian biểu diễn bề mặt không thể phân tách tuyến tính.

TF-IDF vượt trội SBERT về Silhouette (0,1698 so với 0,1303, chênh ≈30%) tại $k = 2$. Nguyên nhân có tính hình học: TF-IDF tạo không gian thưa, siêu nhiều chiều – các văn bản chia sẻ từ vựng chuyên ngành hội tụ thành các vùng cực kỳ dày đặc, tối ưu hóa trực tiếp khoảng cách nội cụm mà Silhouette đo lường. SBERT ánh xạ vào không gian liên tục 384 chiều – hai văn bản đồng nghĩa nhưng không dùng chung từ vựng vẫn nằm gần nhau, tạo cụm trải rộng và mềm dẻo mà Euclidean distance "trừng phạt". Cả hai phương pháp đều đạt điểm cao nhất tại $k = 2$, suy giảm khi tăng k – tín hiệu thống kê mạnh xác nhận **dữ liệu có cấu trúc phân cực nhị phân** rõ nét, không có sự phân mảnh chủ đề phức tạp hơn.

Word2Vec Mean Pooling cho Silhouette thấp nhất (0,0040) và biểu đồ t-SNE co cụm thành một khối tròn đặc – hệ quả của phép Mean Pooling: khi cộng gộp toàn bộ vector trong câu dài, các từ cảm xúc mạnh (*terrible*, *excellent*) bị "pha loãng" bởi hàng chục từ trung tính, khiến vector đại diện hội tụ về một trung bình dẫy đặt không phân biệt được nhãn.

4.5.3 Phân tích hiệu năng phân loại – ROC và AUC

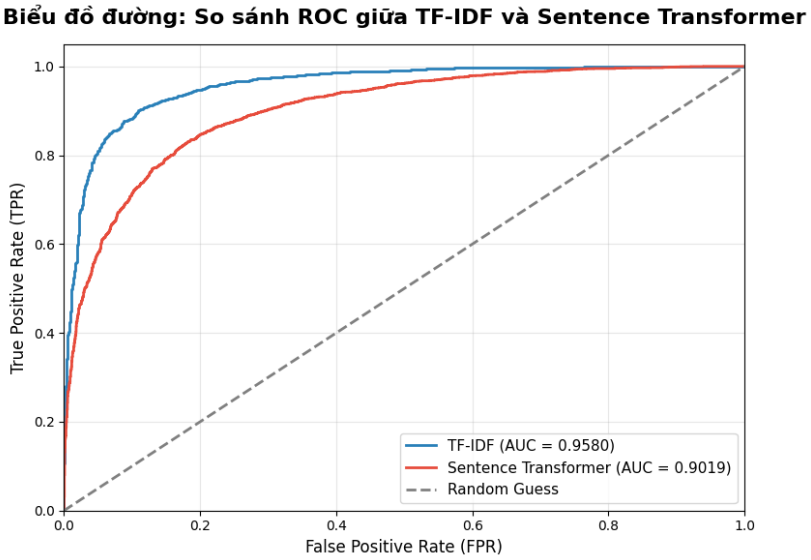

Figure 4.6: Đường cong ROC của TF-IDF Unigram (AUC = 0,8764) và SBERT (AUC = 0,8086) với LinearSVC. TF-IDF hoàn toàn bao trùm lên SBERT trên toàn bộ không gian ngưỡng.

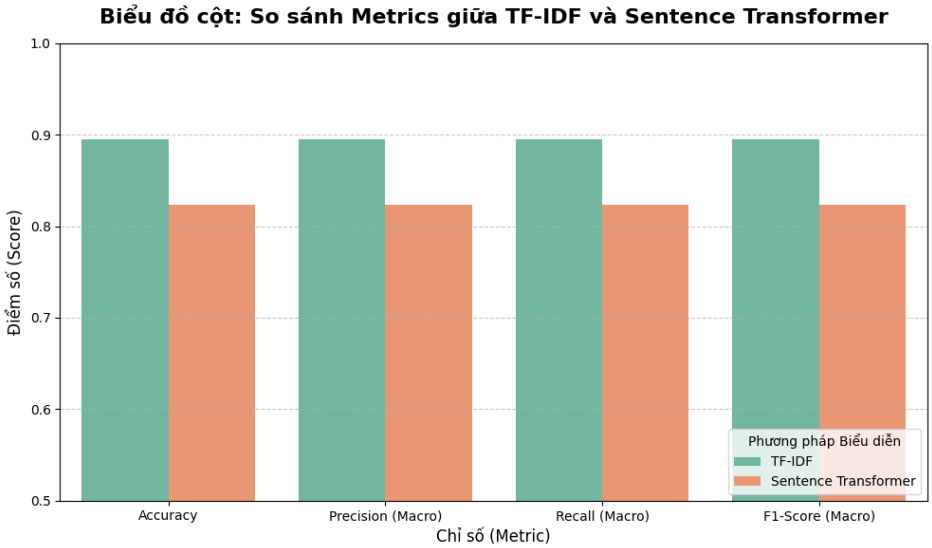

Figure 4.7: So sánh Accuracy, Precision, Recall và F1-Score giữa TF-IDF Unigram và SBERT (LinearSVC). TF-IDF vượt trội ≈7,2% trên mọi chỉ số.

TF-IDF đạt Accuracy và F1-Macro = 0,8954 với Precision và Recall cân bằng hoàn hảo – siêu phẳng LinearSVC chia cắt không gian dữ liệu không bị thiên lệch về một lớp. SBERT chỉ đạt 0,8234, thấp hơn 7,2%. Đường cong ROC của TF-IDF (AUC = 0,8764) hoàn toàn bao trùm SBERT (AUC = 0,8086) – khoảng cách từ các điểm TF-IDF đến ranh giới quyết định rõ ràng hơn, mô hình tự tin hơn ở mọi ngưỡng.

Tuy nhiên, kết quả này **không nên hiểu là TF-IDF "thông minh" hơn SBERT** mà là sự tương thích toán học: ma trận TF-IDF thưa, siêu nhiều chiều tạo ra dữ liệu tuyến tính phân tách được, phù hợp chính xác với LinearSVC. SBERT ánh xạ vào không gian 384 chiều dày đặc, cấu trúc phi tuyến cao – LinearSVC không đủ độ uốn dẻo để len lỏi bóc tách các vùng ngữ nghĩa phức tạp, dẫn đến *linear bottleneck*. Với MLP hoặc SVM-RBF, SBERT được kỳ vọng sẽ vượt trội đáng kể nhờ khai thác được cấu trúc ngữ nghĩa phong phú trong embedding 384 chiều.

Kết luận Phần 3 – Pipeline tối ưu cho dữ liệu văn bản IMDB

- **Làm sạch:** Lowercase → Remove HTML → Remove Special Chars → Normalize Whitespace. (Bỏ qua remove_URL và remove_mention – tác động gần bằng 0 với IMDB.)
- **Tokenization:** Word-level NLTK/spaCy cho TF-IDF; Subword BPE cho Transformer.
- **Stop words:** Danh sách tùy chỉnh – **giữ lại** *not, no, never, without* và từ nhấn mạnh (*even, really, just*).
- **Chuẩn hóa gốc từ:** WordNet Lemmatizer – collision rate 2,32%, accuracy 0,8902, tiết kiệm 43% thời gian so với Original Text.
- **Vector hóa:** TF-IDF Bigram (`min_df` = 5, `max_df` = 0,95) + LinearSVC ⇒ accuracy ≈89,5%.

5. Kết luận và định hướng phát triển

5.1 Tổng hợp so sánh ba loại dữ liệu

Table 5.1: So sánh tổng hợp ba nhóm dữ liệu trong báo cáo

Tiêu chí	**Ảnh số (Intel)**	**Bảng (Amazon)**	**Văn bản (IMDB)**
Quy mô	14.034 / 13.974 sạch	42.675 sp, 17 đặc trưng	50.000 bài, 2 nhãn
Kiểm định chính	pHash + ANOVA F-test	D'Agostino–Pearson [1], Little's MCAR	Mann–Whitney U, Zipf
Thách thức chính	Semantic gap: 4 lớp chồng lấp trong t-SNE	Dữ liệu thiếu MAR/MNAR; power-law distribution	Hapax Legomena 37%; ngữ cảnh phủ định
Chuẩn hóa	Z-score per-channel (HSV)	RobustScaler (IQR)	TF-IDF (`min_df` = 5)
Kết quả tốt nhất	$\approx$ 55% (k-NN/LR)	RMSE TB: 2.938,63 (k-NN $k = 10$)	89,54% (TF-IDF + LinearSVC)
Hướng cải tiến	CNN + Transfer Learning	Category-wise EDA + RF Imputer	SBERT + MLP/SVM-RBF

Ba nhóm dữ liệu minh chứng rằng tiền xử lý là quá trình ra quyết định phụ thuộc sâu vào bản chất biểu diễn của dữ liệu. Với **ảnh số**, mục tiêu trọng tâm là bảo toàn

tín hiệu màu sắc và cấu trúc không gian – kết quả t-SNE xác nhận màu là đặc trưng định danh chính (loại GRAY mất 10% accuracy), nhưng ranh giới quyết định phi tuyến đòi hỏi CNN. Với **dữ liệu bảng**, trọng tâm là kiểm soát rủi ro thống kê: MCAR test định hướng chiến lược imputation, Jaccard thấp giữa các phương pháp outlier detection buộc phải dùng ensemble. Với **văn bản**, bài toán cốt lõi là kiềm chế bùng nổ chiều đặc trưng theo Zipf (99.230 $\rightarrow$ < 55.000 sau min_df) và bảo toàn ngữ cảnh phủ định. Triết lý chung: can thiệp vừa đủ để dữ liệu trở nên học được mà vẫn giữ cấu trúc thông tin quan trọng nhất.

5.2 Hạn chế của nghiên cứu

Báo cáo có ba hạn chế đáng lưu ý. Thứ nhất, ablation study cho ảnh và văn bản chỉ dùng mô hình tuyến tính (k-NN, LR, LinearSVC); kết luận về kích thước ảnh tối ưu hoặc không gian màu phù hợp có thể thay đổi đáng kể khi áp dụng CNN. Thứ hai, RMSE imputation được đo trên 10% giá trị bị che nhân tạo theo cơ chế MCAR – trong khi dữ liệu thực tế theo MAR/MNAR, nên kết quả có thể không đại diện hoàn toàn. Thứ ba, Silhouette Score dùng để so sánh TF-IDF và SBERT bị thiên lệch về cụm hình cầu trong không gian Euclid, chưa đánh giá đúng chất lượng ngữ nghĩa của SBERT trong không gian dày đặc.

5.3 Định hướng nghiên cứu tiếp theo

Với **dữ liệu ảnh**, thử nghiệm CNN (LeNet-5, ResNet-50) và fine-tune backbone EfficientNet hoặc MobileNetV3 tiền huấn luyện trên ImageNet. Khi dùng CNN, kích thước 64×64 hoặc lớn hơn cần được đánh giá lại vì CNN học cấu trúc không gian trực tiếp mà không qua PCA bottleneck.

Với **dữ liệu bảng**, bổ sung phân tích Feature Selection đầy đủ (ANOVA F-test, Random Forest importance, RFE với 5-fold CV) như yêu cầu của đề bài. Thêm mã hóa biến phân loại nâng cao (Target Encoding với cross-validation, Binary Encoding cho high-cardinality variables). Thử nghiệm Random Forest Imputer trong khung MICE để mô hình hóa quan hệ phi tuyến giữa các biến.

Với **dữ liệu văn bản**, kết hợp SBERT [6] với MLP hoặc SVM-RBF để đánh giá đúng tiềm năng của biểu diễn dày đặc. Xây dựng N-gram tùy chỉnh (negation N-gram) để giải mã chính xác các cấu trúc phủ định phức tạp hơn. Phân tích MI chi tiết hơn theo từng N-gram để xác định ngưỡng `min_df` và `max_df` tối ưu bằng grid search.

Tài liệu tham khảo

[1] J. A. Little, "A test of missing completely at random for multivariate data with missing values," *Journal of the American Statistical Association*, vol. 83, no. 404, pp. 1198–1202, 1988.

[2] S. van Buuren and K. Groothuis-Oudshoorn, "mice: Multivariate imputation by chained equations in R," *Journal of Statistical Software*, vol. 45, no. 3, pp. 1–67, 2011.

[3] J. Canny, "A computational approach to edge detection," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. PAMI-8, no. 6, pp. 679–698, 1986.

[4] L. van der Maaten and G. Hinton, "Visualizing data using t-SNE," *Journal of Machine Learning Research*, vol. 9, pp. 2579–2605, 2008.

[5] G. Salton and C. Buckley, "Term-weighting approaches in automatic text retrieval," *Information Processing & Management*, vol. 24, no. 5, pp. 513–523, 1988.

[6] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence embeddings using Siamese BERT-networks," in *Proc. EMNLP-IJCNLP*, 2019, pp. 3982–3992.

[7] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. NAACL-HLT*, 2019, pp. 4171–4186.

[8] P. Bansal, "Intel Image Classification," Kaggle dataset, 2018. [Online]. Available: https://www.kaggle.com/puneet6060/intel-image-classification

[9] A. Maas, R. Daly, P. Pham, D. Huang, A. Ng, and C. Potts, "Learning word vectors for sentiment analysis," in *Proc. ACL*, 2011, pp. 142–150.

[10] I. Sherazi, "Amazon Products Sales Dataset 42K+ Items – 2025," Kaggle dataset, 2025. [Online]. Available: https://www.kaggle.com/datasets/iamsouravbanerjee/amazon-product-dataset-2023

[11] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[12] S. Bird, E. Klein, and E. Loper, *Natural Language Processing with Python*. Sebastopol, CA, USA: O'Reilly Media, 2009.